

Fortgeschrittene Lineare Algebra und Analytische Geometrie

04 Innere Produkte, Orthogonalität, Definitheit

Martin Zaefferer

Quellen

- Strang. 2020. Linear Algebra for Everyone. Wellesley-Cambridge Press.
- Deisenroth, Faisal, Ong. 2021. Mathematics for Machine Learning. Cambridge University Press
- Kenji Hiranabe. 2023. The Art of Linear Algebra. <https://github.com/kenjihiranabe/The-Art-of-Linear-Algebra>

Innere Produkte, Orthogonalität, Definitheit

Erinnerung: Normen, Vektorräume

Norm

- Normen:

- Funktionen $f(\vec{x})$ mit $f : \mathbb{R}^n \rightarrow \mathbb{R}$
 - Schreibweise üblich: $f(\vec{x}) = ||\vec{x}||$
- Eigenschaften:
 - Dreiecksungleichung: $||\vec{x} + \vec{y}|| \leq ||\vec{x}|| + ||\vec{y}|| \quad \forall \vec{x}, \vec{y} \in \mathbb{R}^n$
 - Absolute Homogenität: $||s\vec{x}|| = |s| ||\vec{x}|| \quad \forall \vec{x} \in X \text{ und } \forall s \in \mathbb{R}$
 - Definitheit: $\forall \vec{x} \in \mathbb{R}^n$ gilt: wenn $||\vec{x}|| = 0$ dann $\vec{x} = \vec{0}$

Wichtige Normen

L1-Norm

$$\|\vec{x}\|_1 = \sum_{i=1}^n |x_i|$$

L2-Norm (entspricht Euklidischer)

$$\|\vec{x}\|_2 = |\vec{x}| = \sqrt{\sum_{i=1}^n |x_i|^2}$$

p -Norm (Mit $p \geq 1$, für $p < 1$:
Dreiecksungleichung verletzt.)

$$\|\vec{x}\|_p = (\sum_{i=1}^n |x_i|^p)^{1/p}$$

∞ -Norm / Maximum-Norm

$$\|\vec{x}\|_\infty = \max(|x_1|, \dots, |x_n|)$$

Vektorraum

- Raum V mit Elementen $v \in V$ (a.k.a Vektoren)
- Mit zwei Operationen
 - Vektoraddition
 - Skalarmultiplikation

Untervektorräume

- Untervektorräume: Vektorräume beschränkt auf Untermenge $U \subseteq V$
- Mit Eigenschaften:
 - abgeschlossen
 - d.h., alle Operationen auf Elementen von U liefern wieder Elemente in U
 - sowohl für $\oplus$ als auch $\odot$
 - nicht-leer
 - $U \neq \emptyset$

Verknüpfungen müssen bestimmte Gesetze erfüllen (siehe Grundlagenvorlesung)

Von Normen zu Metriken; Räume

Metrik

- Ähnlich dem Konzept der Norm
- Norm:
 - Ordnet *einem* Vektor eine Länge zu
- Metrik:
 - Ordnet *zwei* Vektoren einen Wert zu (einen Abstand bzw. Distanz)
- Metrik zu Menge S ist die Funktion $d : S \times S \rightarrow \mathbb{R}$ mit
 - $d(x, y) \geq 0$, mit $d(x, y) = 0$ nur dann wenn $x = y$
 - $d(x, y) = d(y, x)$
 - $d(x, z) \leq d(x, y) + d(y, z)$ (Dreiecksungleichung)

$$\forall x, y, z \in S$$

Metrische, Normierte Räume

- Wir kennen bereits *Normen* sowie *Vektorräume*
- Und jetzt auch *Metriken*
- Vektorräume, auf denen eine Norm definiert ist:
 - **Normierter Vektorraum** oder normierter Raum
- Vektorräume, auf denen eine Metrik definiert ist:
 - **Metrischer Vektorraum** oder metrischer Raum

Jede Norm auf Vektorraum V erzeugt auch eine Metrik auf V : $d(\vec{x}, \vec{y}) = \|\vec{x} - \vec{y}\|$

Also ist jeder normierte Raum auch ein metrischer Raum

Innere Produkte

Wofür brauchen wir das?

- Innere Produkte wichtig u.a. für bestimmte Machine Learning Modelle
 - Insbesondere: Support Vector Machines
- Aber auch Grundlage für verschiedene andere mathematische Konzepte

Inneres Produkt

- Ein **inneres Produkt** auf einem Vektorraum V ist Funktion $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$, welche erfüllt:

1. Positiv definit: $\langle \vec{x}, \vec{x} \rangle \geq 0$, mit $\langle \vec{x}, \vec{x} \rangle = 0$ nur wenn $\vec{x} = \vec{0}$
2. Linear bzgl. erstem Argument: $\langle \alpha \vec{x} + \beta \vec{y}, \vec{z} \rangle = \alpha \langle \vec{x}, \vec{z} \rangle + \beta \langle \vec{y}, \vec{z} \rangle$
3. Symmetrie: $\langle \vec{x}, \vec{y} \rangle = \langle \vec{y}, \vec{x} \rangle$

$\forall \vec{x}, \vec{y}, \vec{z} \in V$ und $\forall \alpha, \beta \in \mathbb{R}$.

- Der zugehörige Vektorraum V : **Innenproduktraum**
- Jedes innere Produkt auf V erzeugt auch eine Norm auf V : $\|\vec{x}\| = \sqrt{\langle \vec{x}, \vec{x} \rangle}$
 - Somit: Innenproduktraum ist normierter Raum und somit auch metrischer Raum

Anmerkung: Linearität des ersten Arguments und Symmetrie impliziert **Bilinearität**, d.h. beide Argumente sind linear. Innere Produkte sind also Bilinear.

Orthogonale Vektoren

- Zwei Vektoren $\vec{x}, \vec{y}$ sind *orthogonal* wenn:
 - $\langle \vec{x}, \vec{y} \rangle = 0$
- Abkürzende Notation:
 - $\vec{x} \perp \vec{y}$
- Dies ist analog zu uns bekanntem Konzept von orthogonalität in Euklid'schen Räumen
 - Aber hier verallgemeinert auf beliebige Innenprodukträume

Orthonormale Vektoren

- Wenn:
 - $\vec{x} \perp \vec{y}$
 - UND
 - $\|\vec{x}\| = \|\vec{y}\| = 1$
- Dann:
 - $\vec{x}, \vec{y}$ sind *orthonormal*

Beispiel: Das Skalarprodukt

- Uns bereits bekanntes inneres Produkt ist Skalarprodukt

$$\langle \vec{x}, \vec{y} \rangle = \sum_{i=1}^n x_i y_i = \vec{x}^\top \vec{y}$$

Pythagoras für Innenprodukträume

- Satz des Pythagoras in Euklid'schem Raum:
 - Wenn $\vec{x} \perp \vec{y}$, dann $\|\vec{x} + \vec{y}\|_2^2 = \|\vec{x}\|_2^2 + \|\vec{y}\|_2^2$
- Kann auf Innenprodukträume verallgemeinert werden:
 - Wenn $\vec{x} \perp \vec{y}$, dann $\|\vec{x} + \vec{y}\|^2 = \|\vec{x}\|^2 + \|\vec{y}\|^2$

Nachweis:

- Angenommen: $\vec{x} \perp \vec{y}$, also: $\langle \vec{x}, \vec{y} \rangle = 0$
- Somit:

$$\|\vec{x} + \vec{y}\|^2 = \langle \vec{x} + \vec{y}, \vec{x} + \vec{y} \rangle = \underbrace{\langle \vec{x}, \vec{x} \rangle}_{\|\vec{x}\|^2} + \underbrace{\langle \vec{y}, \vec{x} \rangle}_0 + \underbrace{\langle \vec{x}, \vec{y} \rangle}_0 + \underbrace{\langle \vec{y}, \vec{y} \rangle}_{\|\vec{y}\|^2} = \|\vec{x}\|^2 + \|\vec{y}\|^2$$

Anmerkung: $\|\vec{x}\| = \sqrt{\langle \vec{x}, \vec{x} \rangle}$, beliebige Norm, die durch Innenprodukt erzeugt wird

Cauchy-Schwarz Ungleichung

- Ab und an nützlich zum Nachweis von Grenzen:

$$|\langle \vec{x}, \vec{y} \rangle| \leq \|\vec{x}\| \cdot \|\vec{y}\|$$

$\forall \vec{x}, \vec{y} \in V.$

$|\langle \vec{x}, \vec{y} \rangle| = \|\vec{x}\| \cdot \|\vec{y}\|$ wenn $\vec{x}, \vec{y}$ linear abhängig sind (Vielfache voneinander)

Noch mehr Erinnerungen

Erinnerung: Regeln für Transponieren

- $(A^{\top})^{\top} = A$
- $(A + B)^{\top} = A^{\top} + B^{\top}$
- $(\alpha A)^{\top} = \alpha A^{\top}$
- $(AB)^{\top} = B^{\top} A^{\top}$

Erinnerung: Eigenwerte und Eigenvektoren

- Quadratische $n \times n$ Matrix A
- Für Eigenwert λ von A
- Und Eigenvektor $\vec{y}$ von A (mit $\vec{y} \neq \vec{0}$)
- Gilt $A\vec{y} = \lambda\vec{y}$

Eigenvektoren und Orthogonalität

Potenzen von Matrizen

mit $k, m \in \mathbb{N} \setminus \{0\}$

gilt per Definition

$$A^0 = E$$

und

$$A^k = \underbrace{A \cdot A \cdot \dots \cdot A}_{k \text{ mal}}$$

Bekannte Potenzgesetze gelten somit auch: $A^k A^m = A^{k+m}$; $(A^k)^m = A^{km}$.

Tatsächlich gilt auch für Inverse: $A^{-k} = (A^{-1})^k$.

Nützliche Eigenschaften von Eigenvektoren

Wenn $\vec{x}$ ein Eigenvektor von A ist, mit Eigenwert λ :

- Für jedes $\gamma \in \mathbb{R}$ ist $\vec{x}$ auch ein Eigenvektor von $A + \gamma E$, mit Eigenwert $\lambda + \gamma$
 - Ergibt sich aus charakteristischer Gleichung
- Wenn A^{-1} existiert ist $\vec{x}$ Eigenvektor von A^{-1} mit Eigenwert λ^{-1}
 - Weil: $\vec{x} = A^{-1}A\vec{x} = A^{-1}(\lambda\vec{x}) = \lambda A^{-1}\vec{x}$
 - und somit $\lambda^{-1}\vec{x} = A^{-1}\vec{x}$
- $A^k\vec{x} = \lambda^k\vec{x}$ für beliebige $k \in \mathbb{Z}$

Spur

- **Spur** einer quadratischen Matrix ist Summe der Diagonalelemente $\text{spur}(A) = \sum_{i=1}^n A_{ii}$

Eigenschaften:

- $\text{spur}(A + B) = \text{spur}(A) + \text{spur}(B)$
- $\text{spur}(\alpha A) = \alpha \text{spur}(A)$
- $\text{spur}(A^\top) = \text{spur}(A)$
- $\text{spur}(ABCD) = \text{spur}(BCDA) = \text{spur}(CDAB) = \text{spur}(DABC)$ (Invarianz gegenüber **zyklischer Vertauschung**)
 - Funktioniert auch für mehr als 4 Matrizen
 - Achtung, nur **zyklisch**, z.B. $\text{spur}(ABCD) \neq \text{spur}(BACD)$
- Ausserdem: Spur ist auch Summe der Eigenwerte, $\text{spur}(A) = \sum_i \lambda_i(A)$

Orthogonale Matrizen

- Matrix $Q \in \mathbb{R}^{n \times n}$ ist *orthogonal*
 - wenn alle Spalten paarweise orthogonale Vektoren sind (Skalarprodukte sind Null)
 - und alle Spalten normalisiert sind, d.h., mit Länge von Eins
- Äquivalent: alle Spalten paarweise orthonormal
- Damit folgt:
 - $Q^T Q = Q Q^T = E$
 - bzw. $Q^T = Q^{-1}$
- Orthogonalmatrizen erlauben also sehr einfach die Inverse zu bestimmen

Manchmal synonym: *orthonormale Matrizen*

Orthogonale Matrizen

- Orthogonale Matrizen (als Transformation) verändern nicht die Eigenschaften innerer Produkte:
$$(Q\vec{x})^\top(Q\vec{y}) = \vec{x}^\top Q^\top Q \vec{y} = \vec{x}^\top E \vec{y} = \vec{x}^\top \vec{y}$$
- Daher wird z.B. wird auch die L2 Norm beibehalten $\|Q\vec{x}\|_2 = \sqrt{(Q\vec{x})^\top(Q\vec{x})} = \sqrt{\vec{x}^\top \vec{x}} = \|\vec{x}\|_2$

Somit: Transformation mittels Multiplikation einer Orthogonalmatrix behält auch die ursprünglichen Längen (Normen) bei. Somit spiegeln oder rotieren Orthogonalmatrizen einen Vektor um den Ursprung.

Zerlegungen

QR Zerlegung

- $A = QR$
 - Q ist *orthogonal*, d.h., $Q^T Q = E$
 - R ist obere Dreiecksmatrix
- Nützlich weil stabil, schnell zu berechnen
- Existiert für alle quadratische Matrizen
- Für nicht quadratisches A existiert reduzierte Form mit $A = Q \begin{bmatrix} R \\ 0 \end{bmatrix}$
- Spart bei linearer Regression die Bestimmung von $X^T X$:
 - $X^T X = R^T Q^T Q R = R^T R$




Bild: Kenji Hiranabe. 2023. The Art of Linear Algebra.

QR Zerlegung

- Anwendung zur Lösung eines LGS:
 - $A\vec{x} = \vec{b}$
 - $A = QR$
 - $QR\vec{x} = \vec{b}$.
 - Zweischrittig lösen, ähnlich wie bei LU
 - $Q\vec{y} = \vec{b}$
 - Durch Multiplikation mit Inverser Q^T
 - $R\vec{x} = \vec{y}$
 - Durch Rückwärtseinsetzen

Spektralzerlegung

Wenn $A \in \mathbb{R}^{n \times n}$ symmetrisch ist, existiert eine *Orthonormalbasis* für $\mathbb{R}^n$ bestehend aus Eigenvektoren von A .

Dies führt zur Spektralzerlegung von A :

- Orthonormalbasis der Eigenvektoren $\vec{q}_1, \dots, \vec{q}_n$ und -werte $\lambda_1, \dots, \lambda_n$
- $Q = [\vec{q}_1 \ \dots \ \vec{q}_n]$ und $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$
- Weil $A\vec{q}_i = \lambda_i\vec{q}_i$ für jedes i :

$$AQ = Q\Lambda$$

- Umformung mit $Q^T = Q^{-1}$, Multiplikation von rechts:

$$A = Q\Lambda Q^T$$

Spektralzerlegung

$$A = Q\Lambda Q^\top$$

Erlaubt z.B. Berechnung der Inversen über $A^{-1} = Q\Lambda^{-1}Q^\top$.




Bild: Kenji Hiranabe. 2023. The Art of Linear Algebra.

Anmerkung: Inverse einer Diagonalmatrix ist die Matrix der Kehrwerte der Diagonale.

Anmerkung: Wir kennen diese Zerlegung im Grunde bereits: Eigenzerlegung.

bzw. $A = S\Lambda S^{-1}$. Allerdings hier für Spezialfall symmetrisches A und orthonormale Eigenvektoren.

Definitheit von Matrizen

Positiv (semi-)definite Matrizen

- Voraussetzung: A ist **symmetrisch** (somit auch quadratisch)
- A ist **positiv semi-definit** (PSD) wenn:
 - $\forall \vec{x} \in \mathbb{R}^n$ gilt $\vec{x}^\top A \vec{x} \geq 0$.
 - Alternative Schreibweise $A \succeq 0$
- A ist **positiv definit** (PD) wenn:
 - $\forall \vec{x} \in \mathbb{R}^n \setminus \{\vec{0}\}$ gilt $\vec{x}^\top A \vec{x} > 0$.
 - Alternative Schreibweise $A \succ 0$

Negativ (semi-)definit (N(S)D) ergibt sich entsprechend durch Umkehrung der vergleichenden Operatoren, bzw. $A \prec 0$, $A \preceq 0$

PSD Matrizen und Eigenwerte

- PSD Matrix: alle Eigenwerte sind positiv oder Null
- PD Matrix: alle Eigenwerte sind positiv

Nachweis: Annahme, dass $A \succeq 0$, Eigenvektor $\vec{x}$ und Eigenwert λ . Dann:

$$0 \leq \vec{x}^\top A \vec{x} \quad (1)$$

$$= \vec{x}^\top (\lambda \vec{x}) \quad (2)$$

$$= \lambda \vec{x}^\top \vec{x} \quad (3)$$

$$= \lambda \|\vec{x}\|_2^2 \quad (4)$$

Es muss gelten: $\vec{x} \neq \vec{0}$ (Eigenvektor!), also $\|\vec{x}\|_2^2 > 0$, also beide Seiten durch $\|\vec{x}\|_2^2$ teilbar.

$$0 \leq \lambda$$

(Nachweis nur für eine Richtung. Andere Richtung sparen wir uns, gilt aber auch.)

Beispiel: Nutzen von PSD Matrizen

Wenn $A \in \mathbb{R}^{m \times n}$

- dann ist $A^T A$ PSD
- und wenn zudem $\mathcal{N}(A) = \{\vec{0}\}$, dann ist $A^T A$ PD

Nützlich weil:

- Die Matrix $X^T X$ für lineare Regression immer lösbar mit Methoden wie Cholesky, die P(S)D erfordern!

Beispiel: Nutzen von PSD Matrizen

Problem:

- manchmal mit **PSD** $X^T X$ trotzdem numerisch nicht lösbar

Lösung:

- Wenn A PSD und $\epsilon > 0$, dann ist $A + \epsilon E$ **PD**
- D.h. durch Addieren einer Konstanten ϵ zur Diagonalen kann Lösbarkeit (und Invertierbarkeit) ermöglicht werden
- Führt in der Praxis zu einer Glättung (d.h., des Regressionsmodells)
 - Zu wenig Glättung (ϵ ist klein): numerische Probleme bestehen weiter (& mögliches 'Overfitting')
 - Zu viel Glättung (ϵ ist groß): Modell bildet Daten nur schlecht ab

Somit häufig ein **Tuning-Parameter**: Gezielt so einzustellen, dass Modell 'gut funktioniert'

R-Lab part 1: Mehrere Variablen

Advertising data

```
1 ads <- read.csv("../GrundLinAlg/data/Advertising.csv", row.names=1)
2 A <- as.matrix(ads)
3 head(A)
```

	TV	radio	newspaper	sales
1	230.1	37.8	69.2	22.1
2	44.5	39.3	45.1	10.4
3	17.2	45.9	69.3	9.3
4	151.5	41.3	58.5	18.5
5	180.8	10.8	58.4	12.9
6	8.7	48.9	75.0	7.2

Lineare Regression (Standardvorgehen)

Vorbereitung

```
1 X <- cbind(1,A[,1:3])
2 y <- A[,4]
3 XT <- t(X)
4 XTX <- XT %*% X
5 XTy <- XT %*% y
```

Lösung mit Cholesky


$$\vec{c} = (X^T X)^{-1} X^T \vec{y}$$

```
1 L <- chol(XTX)
2 y <- forwardsolve(t(L), XTy)
3 (cv <- backsolve(L, y))
```

```
      [,1]
[1,]  2.938889369
[2,]  0.045764645
[3,]  0.188530017
[4,] -0.001037493
```

Plot

```
1 xTV <- seq(from=0,to=250,by=5)
2 xTV_FixedRadioNewspaper <- cbind(1,xTV,25,25)
3 ySales <- xTV_FixedRadioNewspaper %*% cv
4 par(mar=c(3,3,0.2,0.5),mgp=c(1.4,0.6,0))
5 plot(xTV,ySales,type="l",lwd=2,col="blue",ylim=range(ads$sales))
6 points(ads$TV,ads$sales,col="red",pch=20)
```



Lineare Regression

Vorbereitung

```
1 Xorig <- A[,1:3]
2 X <- as.matrix(dist(Xorig)) #!!!
3 y <- A[,4]
4 XT <- t(X)
5 XTX <- XT %*% X
6 XTy <- XT %*% y
```

Lösung mit Cholesky

$$\vec{c} = (X^T X)^{-1} X^T \vec{y}$$

```
1 L <- chol(XTX)
2 y <- forwardsolve(t(L), XTy)
3 head(cv <- backsolve(L, y))
```

```
      [,1]
[1,] -0.085674591
[2,]  0.057035111
[3,] -0.076810379
[4,]  0.008067159
[5,]  0.010228226
[6,]  0.087387211
```

```
1 dim(cv)
```


```
[1] 200  1
```

Plot

```

1 xTV <- seq(from=0,to=250,by=5)
2 xTV_FixedRadioNewspaper <- cbind(xTV,25,25)
3 fdist <- function(xx,XX){
4   xx <- matrix(xx,1)
5   Rfast::dista(xx,XX)
6 }
7 xTV_distances <- apply(xTV_FixedRadioNewspaper,1,fdist,XX=Xorig)
8 xTV1 <- t(xTV_distances)
9 ySales <- xTV1 %*% cv
10 par(mar=c(3,3,0.2,0.5),mgp=c(1.4,0.6,0))
11 plot(xTV,ySales,type="l",lwd=2,col="blue",ylim=range(ads$sales))
12 points(ads$TV,ads$sales,col="red",pch=20)

```



R-Lab part 2: 1 Variable

Lineare Regression (Standardvorgehen)

Vorbereitung

```
1 #X <- cbind(1,A[,1:3])
2 X <- cbind(1,A[,1])
3 y <- A[,4]
4 XT <- t(X)
5 XTX <- XT %*% X
6 XTy <- XT %*% y
```

Lösung mit Cholesky

$$\vec{c} = (X^T X)^{-1} X^T \vec{y}$$

```
1 L <- chol(XTX)
2 y <- forwardsolve(t(L), XTy)
3 (cv <- backsolve(L, y))
```


```
      [,1]
[1,] 7.03259355
[2,] 0.04753664
```

Plot

```

1 xTV <- seq(from=0,to=250,by=5)
2 xTV_FixedRadioNewspaper <- cbind(1,xTV)
3 ySales <- xTV_FixedRadioNewspaper %*% cv
4 par(mar=c(3,3,0.2,0.5),mgp=c(1.4,0.6,0))
5 plot(xTV,ySales,type="l",lwd=2,col="blue",ylim=range(ads$sales))
6 points(ads$TV,ads$sales,col="red",pch=20)

```



Lineare Regression (mit Innerem Produkt)

Vorbereitung

```
1 Xorig <- A[,1]
2 X <- as.matrix(dist(Xorig))
3 y <- A[,4]
4 XT <- t(X)
5 XTX <- XT %*% X
6 XTy <- XT %*% y
```

Lösung mit Cholesky

$$\vec{c} = (X^T X)^{-1} X^T \vec{y}$$

```
1 L <- chol(XTX+diag(ncol(XTX)))
2 y <- forwardsolve(t(L), XTy)
3 head(cv <- backsolve(L, y))
```

```
      [,1]
[1,] -1.74929412
[2,] -0.02843591
[3,] -0.05647871
[4,] -1.64054087
[5,]  1.66328486
[6,] -0.09836109
```

```
1 dim(cv)
```

```
[1] 200  1
```

Anmerkung: Die Addition der Diagonalmatrix 'glättet' die Regression etwas und vermeidet hier numerische Probleme bei `chol()`

Plot

```

1 xTV <- seq(from=0,to=250,by=5)
2 xTV_FixedRadioNewspaper <- cbind(xTV)
3 fdist <- function(xx,XX){
4   xx <- matrix(xx,1)
5   Rfast::dista(xx,XX)
6 }
7 xTV_distances <- apply(xTV_FixedRadioNewspaper,1,fdist,XX=Xorig)
8 ySales <- t(xTV_distances) %*% cv
9 par(mar=c(3,3,0.2,0.5),mgp=c(1.4,0.6,0))
10 plot(xTV,ySales,type="l",lwd=2,col="blue",ylim=range(ads$sales))
11 points(ads$TV,ads$sales,col="red",pch=20)

```

