

Zerlegungen mit Farben verstehen

Cholesky, SVD & Pseudoinverse

Jede Größe hat eine *feste Farbe* – so siehst du in jeder Formel, woher jeder Wert kommt.

So liest du die Farben: In der **Cholesky** bekommt *jeder* Eintrag von L eine eigene Farbe (ℓ_{11} , ℓ_{21} , ℓ_{31} , ℓ_{22} , ℓ_{32} , ℓ_{33}). Taucht ein Eintrag später wieder auf, hat er dieselbe Farbe – du erkennst sofort, welchen *schon berechneten* Wert du einsetzt. In der **SVD/Pseudoinverse** sind die drei Faktoren durchgehend U (grün), Σ (lila), V (blau).

Inhaltsverzeichnis

1 Cholesky-Zerlegung $A = LL^T$	1
1.1 Die Idee hinter der Formel	1
1.2 Beispiel – jeder Eintrag in seiner Farbe	2
2 Singulärwertzerlegung (SVD) $A = U\Sigma V^T$	3
2.1 Woher die Teile kommen (mit Begründung)	3
3 Pseudoinverse A^+	4

1 Cholesky-Zerlegung $A = LL^T$

Intuition. Cholesky ist die *Wurzel einer Matrix*: so wie $9 = 3 \cdot 3$, schreibst du eine symmetrische, positiv definite Matrix als $A = LL^T$ mit einer **unteren Dreiecksmatrix** L . L ist die „Quadratwurzel“ von A .

Voraussetzung – wann geht das überhaupt?

$A = LL^T$ (reelles L , positive Diagonale) existiert **genau dann**, wenn A **symmetrisch** und **positiv definit** ist. Kommt unter einer Wurzel eine Zahl ≤ 0 heraus, ist A *nicht* positiv definit – Cholesky ist also gleichzeitig ein PD-Test.

1.1 Die Idee hinter der Formel

Schreibe $A = LL^T$ komponentenweise: a_{ij} ist das Skalarprodukt von Zeile i und Zeile j von L . Weil L unten dreieckig ist, bricht die Summe bei $\min(i, j)$ ab. Für $i \geq j$:

$$a_{ij} = \underbrace{\sum_{k=1}^{j-1} \ell_{ik} \ell_{jk}}_{\text{schon berechnet}} + \ell_{ij} \ell_{jj}.$$

Nur der **letzte Term** enthält den **gesuchten** Eintrag; der Rest steht schon fest, wenn du **spaltenweise von links** arbeitest. Auflösen nach ℓ_{ij} ergibt die zwei Formeln:

Die zwei Cholesky-Formeln – nach Rolle eingefärbt

■ gesucht (neu) ■ Pivot der Spalte (Teiler) ■ schon berechnet

Diagonale ($i = j$, der Teiler wird zur Wurzel):

$$\ell_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} \ell_{jk}^2}$$

Unter der Diagonale ($i > j$, durch den Pivot teilen):

$$\ell_{ij} = \frac{1}{\ell_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} \ell_{ik} \ell_{jk} \right)$$

In Worten: **neuer Eintrag** = (Soll-Eintrag a_{ij} – schon gebaute Anteile) geteilt durch den **Pivot** ℓ_{jj} . Auf der Diagonale gibt es keinen Pivot zum Teilen – dort steht stattdessen die Wurzel.

1.2 Beispiel – jeder Eintrag in seiner Farbe

Wir bestimmen L für $A = \begin{pmatrix} 9 & 3 & 6 \\ 3 & 5 & 4 \\ 6 & 4 & 14 \end{pmatrix}$. Jeder gesuchte Eintrag hat seine **eigene Farbe**; sobald er später wieder vorkommt, behält er sie:

$$L = \begin{pmatrix} \ell_{11} & 0 & 0 \\ \ell_{21} & \ell_{22} & 0 \\ \ell_{31} & \ell_{32} & \ell_{33} \end{pmatrix} = \begin{pmatrix} 3 & 0 & 0 \\ 1 & 2 & 0 \\ 2 & 1 & 3 \end{pmatrix}.$$

Spalte 1: zuerst der Pivot oben, dann darunter

$$\begin{aligned} a_{11} = 9 &= \ell_{11}^2 & \Rightarrow \ell_{11} &= \sqrt{9} = 3 \\ a_{21} = 3 &= \ell_{21} \cdot \ell_{11} = \ell_{21} \cdot 3 & \Rightarrow \ell_{21} &= \frac{3}{3} = 1 \\ a_{31} = 6 &= \ell_{31} \cdot \ell_{11} = \ell_{31} \cdot 3 & \Rightarrow \ell_{31} &= \frac{6}{3} = 2 \end{aligned}$$

Beachte: in den unteren beiden Zeilen wird $\ell_{11} = 3$ (rot) *wiederverwendet* – es ist der Pivot der ersten Spalte.

Spalte 2: Pivot zuerst, dann der Eintrag darunter

$$\begin{aligned} a_{22} = 5 &= \ell_{21}^2 + \ell_{22}^2 = 1^2 + \ell_{22}^2 & \Rightarrow \ell_{22} &= \sqrt{5-1} = 2 \\ a_{32} = 4 &= \ell_{31} \ell_{21} + \ell_{32} \cdot \ell_{22} = 2 \cdot 1 + \ell_{32} \cdot 2 & \Rightarrow \ell_{32} &= \frac{4-2 \cdot 1}{2} = \frac{4-2}{2} = 1 \end{aligned}$$

Hier siehst du den Sinn der Farben: ℓ_{32} (himmelblau) braucht die schon bekannten $\ell_{31} \ell_{21}$ (Produkt der beiden Werte links daneben) und teilt durch den frischen Pivot ℓ_{22} (grün).

Spalte 3: nur noch der Diagonaleintrag

$$a_{33} = 14 = \ell_{31}^2 + \ell_{32}^2 + \ell_{33}^2 = 2^2 + 1^2 + \ell_{33}^2 \Rightarrow \ell_{33} = \sqrt{14 - 2^2 - 1^2} = \sqrt{14 - 4 - 1} = 3$$

Probe: $LL^T = \begin{pmatrix} 9 & 3 & 6 \\ 3 & 5 & 4 \\ 6 & 4 & 14 \end{pmatrix} = A$. ✓ Keine Wurzel war negativ $\Rightarrow A$ ist positiv definit.

Damit ein LGS lösen

Mit $A = LL^T$ löst du $Ax = b$ in zwei Dreiecksschritten: $\underbrace{Ly = b}_{\text{vorwärts}}$, dann $\underbrace{L^T x = y}_{\text{rückwärts}}$ – wie LU, nur mit *einem* Dreieck.

Typischer Fehler

- **Durch a_{jj} statt durch ℓ_{jj} teilen.** Im Nenner steht immer der *gelbe* Pivot (die Wurzel), nie der ursprüngliche Matrixeintrag.
- **Reihenfolge verdrehen.** ℓ_{32} braucht ℓ_{22} – erst den Pivot oben in Spalte 2 rechnen, dann den Eintrag darunter. Immer spaltenweise von links.
- **Bekannte Anteile vergessen.** Der teal-Term $\sum_{k < j}$ ist Pflicht – bei ℓ_{32} fehlt sonst $\ell_{31} \ell_{21}$.

2 Singulärwertzerlegung (SVD) $A = U\Sigma V^T$

Intuition. Jede Abbildung $x \mapsto Ax$ ist: drehen (V^T), dann strecken (Σ mit Faktoren $\sigma_i \geq 0$), dann drehen (U). Genau das ist

$$A = U\Sigma V^T.$$

Die Farben bleiben im ganzen Abschnitt gleich: U grün, Σ lila, V blau.

Bausteine

Für $A \in \mathbb{R}^{m \times n}$: V ($n \times n$, orthogonal) – rechte Singulärvektoren; Σ ($m \times n$) – Singulärwerte $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$; U ($m \times m$, orthogonal) – linke Singulärvektoren.

2.1 Woher die Teile kommen (mit Begründung)

Der Schlüssel ist $A^T A$. Setzt man $A = U\Sigma V^T$ ein, kürzt sich U wegen $U^T U = I$ heraus:

$$A^T A = V \Sigma^T \underbrace{U^T U}_{=I} \Sigma V^T = V (\Sigma^T \Sigma) V^T.$$

Das ist die **Diagonalisierung** von $A^T A$: V sind die Eigenvektoren, $\lambda_i = \sigma_i^2$ die Eigenwerte. $A^T A$ quadriert die Singulärwerte.

SVD-Rezept

1. $A^T A$ bilden. Eigenwerte λ_i und *normierte* Eigenvektoren $\rightarrow$ Spalten von V .
2. $\sigma_i = \sqrt{\lambda_i}$, absteigend $\rightarrow$ Diagonale von Σ .
3. $u_i = \frac{1}{\sigma_i} A v_i$ (nur für $\sigma_i \neq 0$) $\rightarrow$ Spalten von U .

Warum Schritt 3? Aus $A = U\Sigma V^T$ folgt $Av_i = \sigma_i u_i$, also $u_i = \frac{1}{\sigma_i} Av_i$. U ergibt sich *direkt* aus

A , v_i und σ_i .

Volle SVD von $A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$

Schritt 1 – $A^T A$ & Eigenwerte.

$$A^T A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}, \quad \lambda = 9, 1.$$

Schritt 2 – Singulärwerte. $\sigma_1 = \sqrt{9} = 3$, $\sigma_2 = \sqrt{1} = 1$.

Schritt 3 – V (normierte Eigenvektoren von $A^T A$). $9 \rightarrow (1, 1)^T$, $1 \rightarrow (1, -1)^T$:

$$V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

Schritt 4 – U über $u_i = \frac{1}{\sigma_i} A v_i$.

$$u_1 = \frac{1}{3} A \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad u_2 = \frac{1}{1} A \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

$$U = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}. \quad A = U \Sigma V^T. \checkmark$$

Wozu die SVD?

$\text{rang}(A) = \#\{\sigma_i \neq 0\}$; beste **Rang- k -Näherung** $A_k = \sum_{i \leq k} \sigma_i u_i v_i^T$ (Kompression, PCA).
Im Beispiel: $A_1 = 3 \cdot u_1 v_1^T = \frac{3}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$.

Typischer Fehler

- Σ hat das Format von A ($m \times n$), nicht zwingend quadratisch.
- V enthält die *Eigenvektoren* von $A^T A$ (normiert!), nicht die Eigenwerte.
- $\sigma_i = \sqrt{\lambda_i}$, nicht $\sigma_i = \lambda_i$.

3 Pseudoinverse A^+

Intuition. A^+ ist der bestmögliche Ersatz für eine Inverse, wenn A nicht quadratisch / nicht voll Rang ist: $x = A^+ b$ löst $Ax = b$ „so gut es geht“ (kleinster Fehler bzw. kleinste Norm). Sie entsteht direkt aus der SVD – gleiche Farben wie oben.

Pseudoinverse aus der SVD

$$A^+ = V \Sigma^+ U^T$$

Σ^+ baust du aus Σ in zwei Schritten: (1) jeden $\sigma_i \neq 0$ durch seinen **Kehrwert** $1/\sigma_i$ ersetzen (Nullen bleiben Null), (2) transponieren (Format $n \times m$).

Warum? V und U sind Drehungen ($U^{-1} = U^T$, $V^{-1} = V^T$) – verlustfrei. Nur das Strecken muss rückgängig gemacht werden, und „rückwärts strecken“ heißt „mit $1/\sigma_i$ strecken“. Ist A invertierbar, ist $A^+ = A^{-1}$.

Beispiel 1: der schnelle Diagonalfall

$$A = \begin{pmatrix} 4 & 0 \\ 0 & 0 \\ 0 & 3 \end{pmatrix}, \quad A^T A = \begin{pmatrix} 16 & 0 \\ 0 & 9 \end{pmatrix} \Rightarrow \sigma_1 = 4, \sigma_2 = 3.$$

Σ^+ direkt ablesen: Kehrwerte der Diagonale, dann transponieren:

$$A^+ = \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & 0 & \frac{1}{3} \end{pmatrix}. \quad \text{Probe: } A^+ A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2. \checkmark$$

Beispiel 2: aus der vollen SVD von oben

Mit V, U aus Abschnitt 2 und $\Sigma^+ = \text{diag}(\frac{1}{3}, 1)$:

$$A^+ = V \Sigma^+ U^T = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} \frac{1}{3} & 0 \\ 0 & 1 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} -\frac{1}{3} & \frac{2}{3} \\ \frac{2}{3} & -\frac{1}{3} \end{pmatrix}.$$

Da A invertierbar ist, ist das zugleich A^{-1} – Kontrolle: $A A^+ = I_2. \checkmark$

Brücke zur Ausgleichsrechnung

Bei vollem Spaltenrang ist $A^+ = (A^T A)^{-1} A^T$ – genau die Lösung der **Normalengleichung** $A^T A x = A^T b$ (lineare Regression). Pseudoinverse und „beste Gerade durch Punkte“ sind dieselbe Idee.