

Numerische Methoden — Blueprint

Jede Methode: **Idee** (grau) · **Formel** · **Ablauf** (Schritt für Schritt). Alle 15 Kapitel.

1 — Grundlagen & Fehlerarten

Approximationsfehler

$$\text{Fehler} = |\text{exakter Wert} - \text{Näherungswert}|$$

Fehlerarten — nach Ursache

- **Modellfehler:** Realität vereinfacht.
- **Abbruchfehler:** Verfahren abgeschnitten (Reihe/Gitter).
- **Rundungsfehler:** Maschine speichert ungenau.

Faustfrage: geht's um eine Zahl (Rundung) oder einen Vorgang (Abbruch)?

2 — Diskretisierung & Grid Search

Extremum auf $[a, b]$ durch Durchprobieren finden.

Stützstellen

$$x_i = a + i h, \quad h = \frac{b-a}{N}, \quad i = 0, \dots, N$$

Grid Search

Ablauf: 1) h und alle x_i bestimmen. 2) $f(x_i)$ überall auswerten. 3) besten Wert (Min/Max) wählen. 4) Fehler = |analytisch – numerisch|.

Komplexität

$$\mathcal{O}(N^d)$$

d Dimensionen — Fluch der Dimensionalität.

3 — Gleitkomma (IEEE 754)

Darstellung

$$x = (-1)^s \cdot m \cdot 2^e$$

s Vorzeichen, m Mantisse, e Exponent. single 1+8+23, double 1+11+52 Bit.

Exponent mit Bias

$$e = E - 127 \text{ (lesen)}, \quad E = e + 127 \text{ (speichern)}$$

single, $E \in [0, 255]$.

Zahl → IEEE-Form

Ablauf: 1) Zahl binär schreiben. 2) normalisieren $1.m \times 2^e$. 3) $E = e + 127$, binär. 4) s, E, m zusammensetzen.

$$10_{10} = 1010_2 = 1.010 \times 2^3$$

$$E = 130 = 10000010_2$$

Maschinengenauigkeit

$$\varepsilon_{\text{mach}} = 2^{-t} \quad (t = \text{Mantissenbits})$$

2^t Werte je Zweierpotenz-Intervall; absolute Lücke $\approx \varepsilon_{\text{mach}}|x|$; relative Präzision $\approx 2^{-t}$. single $\approx 1.19 \cdot 10^{-7}$, double $\approx 2.22 \cdot 10^{-16}$.

Wertebereich

Überlauf (zu groß) / Unterlauf (zu klein). Festkomma = feste Stellen, Gleitkomma = bewegliches Komma.

4 — Auslöschung

Subtraktion fast gleicher Zahlen $\Rightarrow$ führende Ziffern weg $\Rightarrow$ großer relativer Fehler.

Vorgehen

Ablauf: 1) beide Zahlen auf gespeicherte Stellenzahl runden. 2) subtrahieren. 3) mit wahrer Differenz vergleichen. Folge: weniger signifikante Stellen als die Eingaben vortäuschen (Pseudo-Genauigkeit).

5 — Fehleranalyse

Symbole: κ Konditionierung, s Stabilität, c Konsistenz (Konvergenz hat keins). f exakt, $\hat{f}$ Verfahren, $\tilde{x} = x \pm \delta$ gestört.

Konditionierung (Problem)

$$\kappa = |f(x) - f(\tilde{x})|$$

Empfindlichkeit des Problems. Klein = gut. $\kappa \approx |f'(x)|\delta$ — je steiler, desto schlechter.

Stabilität (Verfahren)

$$s = \frac{|\hat{f}(\tilde{x}) - \hat{f}(x)|}{|\tilde{x} - x|}$$

Verstärkungsfaktor des Verfahrens. $s \approx 1$: linear.

Konsistenz

$$|\hat{f}(x) - f(x)| \leq c$$

Abstand Verfahren $\leftrightarrow$ Wahrheit bei exaktem Input.

Konvergenz

$\hat{f}(\tilde{x}) \rightarrow f(x)$ für $h \rightarrow 0$, und

Konvergenz = Stabilität + Konsistenz

6 — Newton-Raphson

Nullstelle $f(x^*) = 0$, wenn f' bekannt. Tangente legen, ihre Nullstelle nehmen.

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

Ablauf: 1) $f(x_n)$ und $f'(x_n)$ getrennt ausrechnen. 2) einsetzen $\rightarrow x_{n+1}$. 3) mit x_{n+1} wiederholen bis $|f(x_n)| < \varepsilon$.

Fehlermodus: $f'(x_n) \approx 0$ (Division durch null, falsche Nullstelle, Oszillation). Quadratische Konvergenz: korrekte Stellen verdoppeln sich.

7 — Taylor & Konvergenz

$$f(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(x_n)}{k!} (x - x_n)^k$$

$$= f(x_n) + f'(x_n)(x - x_n) + \frac{f''(x_n)}{2}(x - x_n)^2 + \dots$$

Ablauf: 1) f, f', f'' bei x_n auswerten (gibt Zahlen!). 2) einsetzen — x bleibt Variable, $(x - x_n)$ nicht 0. 3) Ergebnis ist Polynom in x ; erst danach Zahl einsetzen. Newton = 1. Ordnung (Tangente).

Quadratische Konvergenz

$$|e_{n+1}| \leq C |e_n|^2, \quad C = \left| \frac{f''(\xi)}{2f'(\xi^*)} \right|$$

$$10^{-1} \rightarrow 10^{-2} \rightarrow 10^{-4} \rightarrow 10^{-8}.$$

8 — Sekantenverfahren

Wie Newton, aber f' unbekannt — durch Sekantensteigung ersetzt.

$$x_{n+1} = x_n - f(x_n) \cdot \frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})}$$

Ablauf: 1) zwei Startwerte x_0, x_1 . 2) $f(x_0), f(x_1)$. 3) Formel $\rightarrow x_2$ (x_n = neuester!). 4) ältesten verwerfen, wiederholen.

9 — Newton für Optimierung

Extremum = Nullstelle von f' .

$$x_{n+1} = x_n - \frac{f'(x_n)}{f''(x_n)}$$

2.-Ableitungs-Test: $f'' > 0$ Min, $f'' < 0$ Max, $f'' = 0$ unklar.

|f''|-Trick: Nenner $|f''| \Rightarrow$ Schritt immer bergab.

Gradientenabstieg

$$x_{n+1} = x_n - \eta f'(x_n)$$

η Lernrate. SGD: Gradient auf zufälligem Mini-Batch (Monte-Carlo-Schätzung).

10 — Globale Optimierung

$$\text{lokal: } x^* = \arg \min_{x \in N(x_0)} f(x)$$

$$\text{global: } x^* = \arg \min_{x \in \Omega} f(x)$$

Konvex ($f'' \geq 0 \forall x$): lokal = global.

Random Restarts

$$P = 1 - (1 - p)^K, \quad K = \frac{\ln(1 - P)}{\ln(1 - p)}$$

Ablauf: nach K lösen: 1) $(1 - p)^K = 1 - P$. 2) $\ln$ beidseitig. 3) $K = \ln(1 - P) / \ln(1 - p)$. rechts $1 - P$, nicht P !

Basin Hopping

Lokale Optimierung + zufällige Sprünge $\delta \sim D$ vom Minimum aus (kein voller Neustart).

Simulated Annealing

Verschlechterung Δf akzeptiert mit

$$P_{\text{akz}} = \exp(-\Delta f / T), \quad T \downarrow \text{ über Zeit}$$

Stochastik

Rauschen / Mini-Batch glättet die Landschaft, hilft aus lokalen Minima.

11 — Numerische Integration

$I = \int_a^b f dx$ durch einfache Formen (h Teilbreite, $m = \frac{a+b}{2}$).

Einfache Regeln (1 Intervall, $h=b-a$)

$$\text{Mittelpunkt: } (b - a) f(m)$$

$$\text{Trapez: } \frac{h}{2} [f(a) + f(b)]$$

$$\text{Simpson: } \frac{h}{6} [f(a) + 4f(m) + f(b)]$$

Zusammengesetzt (n Teilintervalle)

$$\text{Trapez: } \frac{h}{2} \left[f_0 + 2 \sum_{i=1}^{n-1} f_i + f_n \right]$$

$$\text{Simpson: } \frac{h}{3} \left[f_0 + 4 \sum_{\text{ungerade}} f_i + 2 \sum_{\text{gerade}} f_i + f_n \right]$$

Ablauf: 1) h und Stützstellen. 2) alle f_i . 3) mit Gewichten in die Formel.

Fehler (akkum.): Mittelpunkt/Trapez $\mathcal{O}(h^2)$, Simpson $\mathcal{O}(h^4)$. Simpson exakt bis Grad 3.

Lagrange-Interpolation

$$L_j(x) = \prod_{\substack{m=0 \\ m \neq j}}^n \frac{x - x_m}{x_j - x_m}, \quad p(x) = \sum_j y_j L_j(x)$$

Ablauf: 1) jedes L_j (Schalter: 1 am eigenen Knoten, 0 sonst). 2) $\times y_j$, summieren. 3) ausmultiplizieren, Probe $p(x_k) = y_k$.

12 — Monte-Carlo-Integration

$$I = \int_{\Omega} f \, dx = |\Omega| \cdot \mathbb{E}_{X \sim U(\Omega)}[f(X)]$$

$$\hat{I} = \frac{|\Omega|}{N} \sum_{i=1}^N f(X_i)$$

Ablauf: 1) N Zufallspunkte X_i in Ω . 2) $f(X_i)$ alle, summieren. 3) $\times |\Omega|/N$.

$\sigma_f^2 = \frac{1}{N-1} \sum (f(X_i) - \bar{f})^2$, Standardfehler $SE = \frac{|\Omega| \sigma_f}{\sqrt{N}}$. $\mathcal{O}(1/\sqrt{N})$, dimensionsunabhängig; $N \times 4 \Rightarrow$ Fehler halbiert.

13 — Richardson & Romberg

Trapez-Fehler $T(h) = I + c_1 h^2 + c_2 h^4 + \dots$ — zwei Schätzungen kombinieren tilgt den h^2 -Term.

$$T^* = \frac{4T(h/2) - T(h)}{3} = I + \mathcal{O}(h^4)$$

(ist Simpson); allgemein bei $\mathcal{O}(h^p)$: $\frac{2^p T(h/2) - T(h)}{2^p - 1}$.

Romberg-Tableau

$$T_{i,j} = \frac{4^j T_{i,j-1} - T_{i-1,j-1}}{4^j - 1}$$

Ablauf: 1) Spalte 0: Trapez mit $1, 2, 4, \dots$ Teilintervallen $(T_{0,0}, T_{1,0}, \dots)$. 2) $j=1$: $\frac{4T_{i,0} - T_{i-1,0}}{3}$. 3) $j=2$: $\frac{16T_{i,1} - T_{i-1,1}}{15}$. 4) Diagonale = beste Schätzung.

14 — Differentialgleichungen

Anfangswertproblem $y' = f(t, y)$, $y(t_0) = y_0$, Schrittweite h , $t_{n+1} = t_n + h$.

Euler (global $\mathcal{O}(h)$)

$$y_{n+1} = y_n + h f(t_n, y_n)$$

Ablauf: 1) Steigung $k = f(t_n, y_n)$. 2) $y_{n+1} = y_n + h k$. 3) $t += h$, wiederholen.

RK2 — Mittelpunkt ($\mathcal{O}(h^2)$)

$$k_1 = f(t_n, y_n), \quad k_2 = f\left(t_n + \frac{h}{2}, y_n + \frac{h}{2} k_1\right) \\ y_{n+1} = y_n + h k_2$$

RK4 ($\mathcal{O}(h^4)$)

$$k_1 = f(t_n, y_n) \\ k_2 = f\left(t_n + \frac{h}{2}, y_n + \frac{h}{2} k_1\right) \\ k_3 = f\left(t_n + \frac{h}{2}, y_n + \frac{h}{2} k_2\right) \\ k_4 = f(t_n + h, y_n + h k_3)$$

$$y_{n+1} = y_n + \frac{h}{6} (k_1 + 2k_2 + 2k_3 + k_4)$$

Ablauf: $k_1 \rightarrow k_2 \rightarrow k_3 \rightarrow k_4$ nacheinander (jedes nutzt das vorige), dann gewichtet mitteln. Gewichte $(1, 2, 2, 1)/6 = \text{Simpson}$.

15 — Diskrete Fourier-Transformation

Signal $x_0, \dots, x_{N-1}$ in Frequenzanteile zerlegen.

$$X_k = \sum_{n=0}^{N-1} x_n e^{-2\pi i k n / N}, \quad k = 0, \dots, N-1$$

Twiddle-Faktor (für $N = 4$)

$$W = e^{-2\pi i / 4} = -i$$

Potenzen (periodisch, $kn \bmod 4$):

$$W^0 = 1, \quad W^1 = -i, \quad W^2 = -1, \quad W^3 = i$$

Ablauf: 1) W -Potenzen bereitlegen. 2) je k : $X_k = \sum_n x_n W^{kn}$ (Exponent $kn \bmod N$). 3) Real- und Imaginärteil sammeln.

Deuten & prüfen

- $|X_k|$ = Stärke der Frequenz k
- X_0 = Mittelwert $\cdot N$ (DC-Anteil)
- reeller Eingang $\Rightarrow X_{N-k} = \overline{X_k}$ (Probe!)

Rücktransformation

$$x_n = \frac{1}{N} \sum_{k=0}^{N-1} X_k e^{+2\pi i k n / N}$$

16 — Numerische Stabilität (DL)

log-sum-exp (gegen Überlauf)

$$\log \sum_i e^{x_i} = m + \log \sum_i e^{x_i - m}, \quad m = \max_i x_i$$

Ablauf: 1) $m = \max(x)$. 2) $x_i - m$ (alle ≤ 0). 3) $e^{x_i - m}$, summieren, log. 4) $+m$.

stabile softmax

$$\text{softmax}(x)_i = \frac{e^{x_i - m}}{\sum_j e^{x_j - m}}$$

17 — Moderne Optimierer

g_t Gradient, α Lernrate, $\varepsilon \approx 10^{-8}$; Start $v_0 = s_0 = m_0 = 0$.

Momentum ($\beta \approx 0.9$)

$$v_t = \beta v_{t-1} + g_t, \quad \theta_{t+1} = \theta_t - \alpha v_t$$

Ablauf: je Schritt: v_t updaten $\rightarrow$ Schritt $-\alpha v_t$.

AdaGrad / RMSprop

$$s_t = s_{t-1} + g_t^2 \quad (\text{AdaGrad})$$

$$s_t = \beta_2 s_{t-1} + (1 - \beta_2) g_t^2 \quad (\text{RMSprop})$$

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{s_t} + \varepsilon} g_t$$

Adam = Momentum + RMSprop

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$\theta_{t+1} = \theta_t - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}$$

Ablauf: m_t, v_t updaten $\rightarrow$ Bias-Korrektur $\hat{m}, \hat{v} \rightarrow$ Update.

18 — Kubische Splines

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3$$

C^2 -glatt durch $n+1$ Punkte (n Intervalle, $4n$ Unbekannte).

Bedingungen abzählen

Ablauf: 1) $4n$ Unbekannte. 2) Gleichungen: Interpolation $2n$, C^1 $n-1$, C^2 $n-1 = 4n-2$. 3) es fehlen 2 $\Rightarrow$ Randbedingungen.

Ränder

natürlich: $S'' = 0$ an beiden Enden. **eingespannt:** S' vorgegeben.

19 — Interpolation & Newton-Cotes

Runge-Phänomen

Hochgradige Interpolation auf gleichmäßigen Knoten oszilliert an den Rändern.

Chebyshev-Knoten (gegen Runge)

$$x_k = \cos\left(\frac{(2k+1)\pi}{2(n+1)}\right) \text{ auf } [-1, 1]$$

dichter am Rand $\Rightarrow$ kein Runge.

Newton-Cotes-Familie

Trapez ($n=1$), Simpson ($n=2$), Boole ($n=4$):

$$\frac{2h}{45} [7f_0 + 32f_1 + 12f_2 + 32f_3 + 7f_4]$$

ab $n \geq 8$ negative Gewichte $\Rightarrow$ instabil.