

Übungsblatt 1: Enter Numerical Methods

Zum Vorlesungsskript „Numerical Methods“ (Prof. Dr.-Ing. Mark Schutera),
Kapitel 1, S. 9–16

13. Juni 2026

Hinweise: Gesamtpunktzahl: **40 Punkte**. Die Aufgaben sind nach Schwierigkeit aufsteigend sortiert: Verständnisfragen (Aufgaben 1–3), Standardaufgaben (Aufgaben 4–6), Transfer-/Prüfungsniveau (Aufgaben 7–8). Erst selbst versuchen, Dinge ausprobieren, damit spielen – das ist kein Zeitrennen (vgl. Skript, S. 14). Taschenrechner ist erlaubt; runden Sie, wo nicht anders angegeben, auf vier Nachkommastellen.

Aufgaben

Aufgabe 1: Analytisch vs. numerisch [4 Punkte]

- Definieren Sie in eigenen Worten, was numerische Methoden (numerical methods) sind, und nennen Sie zwei Gründe, warum man Lösungen approximativ statt analytisch exakt berechnet.
- Erläutern Sie kurz, warum numerische Methoden im Machine Learning – insbesondere im Deep Learning – unverzichtbar sind. Nennen Sie mindestens zwei Aspekte.
- Die Sigmoid-Funktion (sigmoid function) ist gegeben durch $\sigma(x) = \frac{1}{1 + e^{-x}}$. Erklären Sie, was eine transzendente Funktion (transcendental function) ist, und begründen Sie, warum die Gleichung $\sigma(x) = 0$ keine geschlossene Lösung (closed-form solution) besitzt. Was ist hier zusätzlich die Besonderheit der „Nullstelle“ von σ ?



Aufgabe 2: Diskretisierung und Schrittweite [4 Punkte] Eine kontinuierliche Funktion $f(x)$, $x \in [a, b]$, wird diskretisiert zu $f(x_i)$ mit $x_i = a + ih$, $i = 0, 1, \dots, N$, und Schrittweite $h = \frac{b-a}{N}$.

- Das Intervall $[0, 2]$ wird mit $N = 8$ Schritten diskretisiert. Berechnen Sie die Schrittweite h , geben Sie alle Gitterpunkte (grid points) x_i an und bestimmen Sie deren Anzahl.
- Das Intervall $[-1, 1]$ soll mit Schrittweite $h = 0.01$ diskretisiert werden. Wie viele Schritte N und wie viele Funktionsauswertungen sind nötig? Was passiert mit dem Rechenaufwand, wenn man h halbiert?
- Warum ist die Wahl der Schrittweite h wichtig? Beschreiben Sie den Zielkonflikt (trade-off) zwischen Genauigkeit und Rechenzeit, und nennen Sie einen Hauptunterschied zwischen einer kontinuierlichen Funktion und ihrer diskretisierten Version samt einer Implikation für das numerische Lösen.




Aufgabe 3: Extrema auf geschlossenen Intervallen [3 Punkte]

- Erklären Sie, warum bei der Suche nach Extrema einer Funktion auf einem geschlossenen Intervall (closed interval) $[a, b]$ neben den kritischen Punkten stets auch die Endpunkte a und b geprüft werden müssen.
- Bestimmen Sie das Minimum und das Maximum von $f(x) = x^2$ auf dem Intervall $[1, 3]$. Gehen Sie systematisch vor: kritische Punkte bestimmen, Lage prüfen, Kandidaten auswerten.



Aufgabe 4: Minimumsuche: analytisch und per Grid Search [6 Punkte] Gesucht ist das Minimum von $f(x) = \cos(x)$ auf dem geschlossenen Intervall $[0, 4]$.

- Bestimmen Sie das Minimum *analytisch*: Berechnen Sie die Ableitung, finden Sie alle kritischen Punkte im Intervall, klassifizieren Sie sie mit der zweiten Ableitung und vergleichen Sie mit den Werten an den Endpunkten.
- Bestimmen Sie das Minimum *numerisch* per Brute-Force-Gittersuche (grid search): Diskretisieren Sie $[0, 4]$ mit Schrittweite $h = 1$, werten Sie f an allen Gitterpunkten aus (Tabelle!) und wählen Sie den Punkt mit dem kleinsten Funktionswert.
- Berechnen Sie den Approximationsfehler (approximation error) zwischen analytischem und numerischem Minimalwert. Was würde mit dem Fehler geschehen, wenn man die Schrittweite verkleinert – und was wäre der Preis dafür?



Aufgabe 5: Lineares 2×2 -System: Substitution vs. Grid Search [6 Punkte] Gegeben ist das lineare Gleichungssystem

$$\begin{bmatrix} 3 & 1 \\ 4 & 2 \end{bmatrix} \begin{bmatrix} w \\ b \end{bmatrix} = \begin{bmatrix} 9 \\ 10 \end{bmatrix}.$$

- Lösen Sie das System *analytisch* per Substitution. Verifizieren Sie Ihre Lösung durch Einsetzen in beide Gleichungen.
- Lösen Sie das System *numerisch* per Grid Search über das Gitter $w, b \in \{0, 2, 4\}$ (Schrittweite 2). Verwenden Sie als Fehlermaß die Summe der absoluten Abweichungen

$$\text{error}_1 = |3w + b - 9|, \quad \text{error}_2 = |4w + 2b - 10|,$$

werten Sie alle $3 \times 3 = 9$ Kombinationen tabellarisch aus und geben Sie das Paar (w, b) mit dem kleinsten akkumulierten Fehler an.


- Vergleichen Sie das Grid-Search-Ergebnis mit der exakten Lösung aus a). Erklären Sie die Abweichung und gehen Sie dabei insbesondere darauf ein, welche Rolle die Wahl des Suchintervalls (vgl. Intervallwahl $[a, b]$) hier spielt.



Aufgabe 6: Lineares 3×3 -System analytisch lösen [6 Punkte] Lösen Sie das folgende System aus drei Gleichungen mit drei Unbekannten (Übungsaufgabe aus dem Skript, Gl. 2, S. 10) per Substitution bzw. Elimination:

$$\begin{bmatrix} 2 & 1 & 3 \\ 1 & 4 & 2 \\ 3 & 2 & 5 \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix} = \begin{bmatrix} 14 \\ 20 \\ 32 \end{bmatrix}$$

Geben Sie die Lösung exakt (als Brüche) an und verifizieren Sie sie in allen drei Gleichungen. Notieren Sie anschließend in ein bis zwei Sätzen, was diese Rechnung im Vergleich zum 2×2 -System über die Skalierung analytischer Lösungen (computational complexity) lehrt.



Aufgabe 7: Komplexität der Grid Search: $\mathcal{O}(N^d)$ [5 Punkte] Eine Grid Search über d Parameter mit je N Gitterpunkten pro Parameter muss N^d Kombinationen auswerten (Ausblick: Komplexität $\mathcal{O}(N^d)$).

- a) Im Skript wird ein 2×2 -System per Grid Search mit 5 Gitterpunkten pro Variable gelöst. Wie viele Kombinationen sind das? Wie viele wären es bei $N = 100$ Gitterpunkten pro Variable und weiterhin $d = 2$?

- b) Ein kleines neuronales Netz habe $d = 10$ Parameter, jeder werde mit $N = 100$ Gitterpunkten abgesucht. Wie viele Kombinationen entstehen? Wie lange dauert die Suche, wenn ein Computer 10^9 Kombinationen pro Sekunde auswertet? Geben Sie das Ergebnis in Sekunden und in Jahren an (1 Jahr $\approx 3.156 \cdot 10^7$ s).
- c) Folgern Sie: Warum ist Brute-Force-Grid-Search für das Training moderner Deep-Learning-Modelle (Millionen Parameter) ungeeignet, obwohl sie für das 2×2 -System gut funktioniert hat? Schlagen Sie – als Denkanstoß im Sinne des Skript-Teasers (S. 16) – eine einfache Idee vor, das Verhältnis von Genauigkeit zu Rechenaufwand der Grid Search zu verbessern.



Aufgabe 8: Transfer: Loss-Minimierung eines linearen Modells [6 Punkte] Ein lineares Modell $\hat{y} = xw$ (lineares Modell ohne Bias; die einfachste Form eines neuronalen Netzes mit einer einzigen Einheit, vgl. Skript S. 14) soll an die Datenpunkte

$$(x_1, y_1) = (1, 2), \quad (x_2, y_2) = (2, 4), \quad (x_3, y_3) = (3, 5)$$

angepasst werden. Als Verlustfunktion (loss function) dient der quadratische Fehler

$$L(w) = \sum_{i=1}^3 (x_i w - y_i)^2.$$

- a) Erklären Sie kurz, warum die Suche nach dem besten Parameter w ein Minimierungsproblem ist und was das mit dem Training von ML-Modellen (Loss-Minimierung) zu tun hat.
- b) Führen Sie eine Grid Search über $w \in [0, 3]$ mit Schrittweite $h = 0.5$ durch: Werten Sie $L(w)$ an allen sieben Gitterpunkten aus (Tabelle) und geben Sie das numerisch gefundene Minimum an.
- c) Bestimmen Sie das Minimum von $L(w)$ auf $[0, 3]$ nun *analytisch* (Ableitung null setzen, zweite Ableitung prüfen, Endpunkte des Intervalls nicht vergessen). Geben Sie w^* exakt und gerundet an, berechnen Sie $L(w^*)$ und den Approximationsfehler $|w_{\text{grid}} - w^*|$ der Grid Search.

Lösungen — erst nach Bearbeitung lesen!

Lösung zu Aufgabe 1

a) Numerische Methoden sind ein Teilgebiet der Mathematik, in dem Lösungen nicht analytisch exakt, sondern *approximativ* berechnet werden. Zwei Gründe (Skript, S. 9): (1) Viele Probleme sind analytisch gar nicht lösbar oder zu komplex, um praktikabel zu sein; (2) man kann Rechenleistung (computational power) anzapfen, um approximative Lösungen effizient zu erhalten.

b) In ML/AI sind numerische Methoden entscheidend für das Training von Modellen, die Optimierung von Parametern und die Simulation komplexer Systeme, wo analytische Lösungen unmöglich (infeasible) sind. Sie ermöglichen den effizienten Umgang mit großen Datensätzen und komplexen Algorithmen, sodass Modelle effektiv aus Daten lernen können, während die Rechenressourcen im Rahmen bleiben. Besonders im Deep Learning (Millionen Parameter, umfangreiche Berechnungen) erleichtern sie die Optimierungsprozesse des Modelltrainings (Skript, S. 9). Zwei beliebige dieser Aspekte genügen.

c) Eine transzendente Funktion kann nicht als endliche Kombination algebraischer Operationen (Addition, Subtraktion, Multiplikation, Division, Wurzeln) ausgedrückt werden und besitzt daher keine geschlossenen Lösungen (Skript, S. 11). Bei $\sigma(x) = \frac{1}{1+e^{-x}}$ macht der Exponentialterm e^{-x} es unmöglich, x mit elementaren Funktionen (Polynome, rationale, trigonometrische Funktionen) zu isolieren. Besonderheit: Die Nullstelle existiert gar nicht – $\sigma(x)$ nähert sich 0 nur asymptotisch für $x \rightarrow -\infty$, erreicht 0 aber für keinen endlichen Wert von x (Skript, Randnotiz S. 11). Es gibt also nicht nur keine geschlossene Lösung, sondern überhaupt keine Lösung von $\sigma(x) = 0$.

Lösung zu Aufgabe 2

a) Schrittweite nach Gl. (4) des Skripts:

$$h = \frac{b-a}{N} = \frac{2-0}{8} = 0.25.$$

Gitterpunkte $x_i = 0 + i \cdot 0.25$ für $i = 0, 1, \dots, 8$:

$$x_i \in \{0, 0.25, 0.5, 0.75, 1, 1.25, 1.5, 1.75, 2\}.$$

Das sind $N+1 = 9$ Gitterpunkte (Achtung: N zählt die *Schritte*, nicht die Punkte).

b) Aus $h = \frac{b-a}{N}$ folgt

$$N = \frac{b-a}{h} = \frac{1-(-1)}{0.01} = \frac{2}{0.01} = 200$$

Schritte, also $N+1 = 201$ Funktionsauswertungen. Halbiert man h (auf 0.005), verdoppelt sich N auf 400 (401 Auswertungen) – der Rechenaufwand wächst in einer Dimension also (näherungsweise) linear mit $1/h$.

c) Kleines h bedeutet ein feineres Gitter: höhere Genauigkeit der Approximation, aber mehr Funktionsauswertungen und damit mehr Rechenzeit; großes h ist billig, aber ungenau. Die Wahl von h steuert also direkt den Kompromiss zwischen Genauigkeit und Rechenaufwand. Hauptunterschied kontinuierlich vs. diskretisiert: Die kontinuierliche Funktion ist auf dem gesamten Intervall definiert, die diskretisierte Version nur an den endlich vielen Gitterpunkten x_i – zwischen den Punkten hat man keine Information, es gilt nur $f(x) \approx f(x_i)$ (Gl. 7 im Skript, S. 16). Implikation: Merkmale zwischen den Gitterpunkten (z. B. das wahre Minimum) können verfehlt werden; jede numerische Lösung trägt einen Approximationsfehler.

Lösung zu Aufgabe 3

a) Auf einem geschlossenen Intervall $[a, b]$ kann ein Extremum an einem kritischen Punkt (Ableitung null oder nicht definiert) im Inneren *oder* an den Endpunkten a, b auftreten – an den

Endpunkten auch dann, wenn die Ableitung dort nicht null ist, weil die Funktion dort schlicht „abgeschnitten“ wird und kein innerer Vergleichspunkt mehr existiert. Wer nur kritische Punkte prüft, kann das tatsächliche Extremum übersehen (Skript, S. 13).

b) $f(x) = x^2$, $f'(x) = 2x$. Kritischer Punkt: $2x = 0 \Rightarrow x = 0$. Aber $0 \notin [1, 3]$ – es gibt also *keinen* kritischen Punkt im Intervall. Die Extrema liegen daher zwingend an den Endpunkten:

$$f(1) = 1, \quad f(3) = 9.$$

Minimum: $f(1) = 1$ bei $x = 1$; Maximum: $f(3) = 9$ bei $x = 3$ – obwohl die Ableitung an beiden Stellen ($f'(1) = 2 \neq 0$, $f'(3) = 6 \neq 0$) nicht verschwindet. Genau das ist die Stolperfalle aus Teil a).

Lösung zu Aufgabe 4

a) Analytisch. $f(x) = \cos(x)$, $f'(x) = -\sin(x)$. Kritische Punkte:

$$-\sin(x) = 0 \iff x = k\pi, \quad k \in \mathbb{Z}.$$

Im Intervall $[0, 4]$ liegen $x = 0$ und $x = \pi \approx 3.1416$ (der nächste Kandidat $2\pi \approx 6.2832 > 4$ liegt außerhalb). Zweite Ableitung: $f''(x) = -\cos(x)$.

$$f''(0) = -\cos(0) = -1 < 0 \text{ (lokales Maximum)}, \quad f''(\pi) = -\cos(\pi) = 1 > 0 \text{ (lokales Minimum)}.$$

Kandidaten auswerten (kritische Punkte *und* Endpunkte):

$$f(0) = \cos(0) = 1, \quad f(\pi) = \cos(\pi) = -1, \quad f(4) = \cos(4) \approx -0.6536.$$

Ergebnis: Das Minimum ist -1 bei $x = \pi \approx 3.1416$.

b) Numerisch (Grid Search, $h = 1$). Mit $h = \frac{4-0}{N} = 1$ ist $N = 4$, also fünf Gitterpunkte $x_i = 0 + i \cdot 1$:

x_i	$f(x_i) = \cos(x_i)$
$x_0 = 0$	$\cos(0) = 1$
$x_1 = 1$	$\cos(1) \approx 0.5403$
$x_2 = 2$	$\cos(2) \approx -0.4161$
$x_3 = 3$	$\cos(3) \approx -0.9900$
$x_4 = 4$	$\cos(4) \approx -0.6536$

Das Minimum unter diesen Werten ist $\cos(3) \approx -0.9900$ bei $x = 3$.

c) Approximationsfehler. Differenz zwischen analytischem und numerischem Minimalwert:

$$|-1 - (-0.9900)| = 0.0100.$$

Eine kleinere Schrittweite legt Gitterpunkte näher an das wahre Minimum bei $x = \pi$ und verkleinert den Fehler (z. B. träfe $h = 0.5$ den Punkt $x = 3$ weiterhin, $h = 0.1$ schon $x = 3.1$ mit $\cos(3.1) \approx -0.9991$). Der Preis: mehr Gitterpunkte, also mehr Funktionsauswertungen und mehr Rechenzeit – der bekannte Genauigkeit-Rechenaufwand-Kompromiss.

Lösung zu Aufgabe 5

a) Substitution. Die Gleichungen lauten

$$(I) \quad 3w + b = 9, \quad (II) \quad 4w + 2b = 10.$$

Aus (I): $b = 9 - 3w$. Einsetzen in (II):

$$4w + 2(9 - 3w) = 10 \Rightarrow 4w + 18 - 6w = 10 \Rightarrow -2w = -8 \Rightarrow w = 4.$$

Rückeinsetzen: $b = 9 - 3 \cdot 4 = 9 - 12 = -3$. **Lösung:** $(w, b) = (4, -3)$. Verifikation: (I): $3 \cdot 4 + (-3) = 12 - 3 = 9 \checkmark$; (II): $4 \cdot 4 + 2 \cdot (-3) = 16 - 6 = 10 \checkmark$.

b) Grid Search. Für jede Kombination (w, b) aus $\{0, 2, 4\}^2$ werden $\text{error}_1 = |3w + b - 9|$ und $\text{error}_2 = |4w + 2b - 10|$ sowie der akkumulierte Fehler (Summe) berechnet:

w	b	$3w + b$ (error_1)	$4w + 2b$ (error_2)	Error
0	0	0 (9)	0 (10)	19
0	2	2 (7)	4 (6)	13
0	4	4 (5)	8 (2)	7
2	0	6 (3)	8 (2)	5
2	2	8 (1)	12 (2)	3*
2	4	10 (1)	16 (6)	7
4	0	12 (3)	16 (6)	9
4	2	14 (5)	20 (10)	15
4	4	16 (7)	24 (14)	21

Der minimale akkumulierte Fehler ist 3 bei $(w, b) = (2, 2)$ (mit * markiert).

c) Vergleich und Diskussion. Die exakte Lösung $(4, -3)$ wird von der Grid Search deutlich verfehlt: Das Gitter liefert $(2, 2)$. Zwei Gründe: Erstens ist das Gitter mit Schrittweite 2 sehr grob. Zweitens – und entscheidend – liegt die wahre Lösung in der b -Richtung ($b = -3$) *außerhalb* des Suchbereichs $[0, 4]$: Egal wie fein man dieses Gitter macht, die Grid Search kann die exakte Lösung nie finden, weil sie nur innerhalb des gewählten Intervalls sucht. Das illustriert die Selbstreflexionsfrage des Skripts (S. 15): Die Wahl des Intervalls $[a, b]$ beeinflusst, welche (Pseudo-)Optima numerisch überhaupt gefunden werden können – die beste Gitterlösung ist nur die beste *innerhalb des Gitters*.

Lösung zu Aufgabe 6

Die Gleichungen lauten

$$(I) \ 2w_1 + w_2 + 3w_3 = 14, \quad (II) \ w_1 + 4w_2 + 2w_3 = 20, \quad (III) \ 3w_1 + 2w_2 + 5w_3 = 32.$$

Schritt 1: (I) nach w_2 auflösen:

$$w_2 = 14 - 2w_1 - 3w_3.$$

Schritt 2: In (II) einsetzen:

$$w_1 + 4(14 - 2w_1 - 3w_3) + 2w_3 = 20 \Rightarrow w_1 + 56 - 8w_1 - 12w_3 + 2w_3 = 20 \Rightarrow -7w_1 - 10w_3 = -36,$$

$$\text{also } 7w_1 + 10w_3 = 36 \quad (II').$$

Schritt 3: In (III) einsetzen:

$$3w_1 + 2(14 - 2w_1 - 3w_3) + 5w_3 = 32 \Rightarrow 3w_1 + 28 - 4w_1 - 6w_3 + 5w_3 = 32 \Rightarrow -w_1 - w_3 = 4,$$

$$\text{also } w_1 = -4 - w_3 \quad (III').$$

Schritt 4: (III') in (II') einsetzen:

$$7(-4 - w_3) + 10w_3 = 36 \Rightarrow -28 - 7w_3 + 10w_3 = 36 \Rightarrow 3w_3 = 64 \Rightarrow w_3 = \frac{64}{3}.$$

Schritt 5: Rückwärts einsetzen:

$$w_1 = -4 - \frac{64}{3} = \frac{-12 - 64}{3} = -\frac{76}{3}, \quad w_2 = 14 - 2\left(-\frac{76}{3}\right) - 3 \cdot \frac{64}{3} = 14 + \frac{152}{3} - 64 = \frac{42 + 152 - 192}{3} = \frac{2}{3}.$$

Lösung:

$$w_1 = -\frac{76}{3} \approx -25.3333, \quad w_2 = \frac{2}{3} \approx 0.6667, \quad w_3 = \frac{64}{3} \approx 21.3333.$$

Verifikation:

$$(I) : 2 \left(-\frac{76}{3} \right) + \frac{2}{3} + 3 \cdot \frac{64}{3} = \frac{-152+2+192}{3} = \frac{42}{3} = 14 \checkmark$$

$$(II) : -\frac{76}{3} + 4 \cdot \frac{2}{3} + 2 \cdot \frac{64}{3} = \frac{-76+8+128}{3} = \frac{60}{3} = 20 \checkmark$$

$$(III) : 3 \left(-\frac{76}{3} \right) + 2 \cdot \frac{2}{3} + 5 \cdot \frac{64}{3} = \frac{-228+4+320}{3} = \frac{96}{3} = 32 \checkmark$$

Lehre zur Skalierung: Schon der Schritt von 2 auf 3 Unbekannte verlangt deutlich mehr Substitutionsschritte, Zwischenterme und Sorgfalt (Bruchrechnung!). Mit wachsender Systemgröße (Tausende Gleichungen mit Tausenden Unbekannten) werden analytische Handlösungen wegen der Rechenkomplexität und Zeitbeschränkungen unpraktikabel – genau das Argument des Skripts (S. 10–11) für numerische, computergestützte Methoden.

Lösung zu Aufgabe 7

a) Mit $N = 5$ Gitterpunkten und $d = 2$ Variablen: $N^d = 5^2 = 25$ Kombinationen (genau die 25 Zeilen der Tabelle 1 im Skript, S. 15; das Skript spricht von „only 100 operations“, also etwa vier Rechenoperationen pro Kombination). Mit $N = 100$ und $d = 2$: $100^2 = 10\,000$ Kombinationen – für einen Computer immer noch trivial.

b) Mit $N = 100$ und $d = 10$:

$$N^d = 100^{10} = (10^2)^{10} = 10^{20} \text{ Kombinationen.}$$

Bei 10^9 Auswertungen pro Sekunde:

$$t = \frac{10^{20}}{10^9} = 10^{11} \text{ s} \quad \Rightarrow \quad \frac{10^{11}}{3.156 \cdot 10^7 \text{ s/Jahr}} \approx 3.17 \cdot 10^3 \text{ Jahre,}$$

also rund 3 170 Jahre – für ein „kleines“ Netz mit nur zehn Parametern.

c) Die Anzahl der Kombinationen wächst *exponentiell* in der Zahl der Parameter d (Fluch der Dimensionalität, curse of dimensionality). Deep-Learning-Modelle haben Millionen Parameter; N^d ist dann astronomisch groß und Brute Force vollkommen aussichtslos – deshalb braucht das Modelltraining effizientere numerische Optimierungsverfahren (Ausblick des Kurses, z. B. ableitungsbasierte Methoden). Idee zum Teaser (S. 16): *adaptive bzw. verfeinerte Suche* – erst mit grobem Gitter suchen, dann nur in der Umgebung des besten Kandidaten mit feinerem Gitter weitersuchen. So erreicht man die Genauigkeit eines feinen Gitters zu einem Bruchteil der Auswertungen (in 1D z. B. $10 + 10 = 20$ statt 100 Auswertungen für die gleiche Endauflösung).

Lösung zu Aufgabe 8

a) Der Loss $L(w)$ misst, wie stark die Modellvorhersagen $\hat{y}_i = x_i w$ von den beobachteten Werten y_i abweichen. Der beste Parameter ist der mit der kleinsten Gesamtabweichung – die Suche nach w ist also die Minimierung von $L(w)$. Genau das ist Training im Machine Learning: Modellparameter werden so eingestellt, dass eine Verlustfunktion minimal wird; xw (bzw. $xw + b$) ist dabei die einfachste Form eines neuronalen Netzes mit einer einzigen Einheit (Skript, S. 14). Die Grid Search aus b) ist die primitivste numerische Methode dafür.

b) **Grid Search** über $w \in \{0, 0.5, 1, 1.5, 2, 2.5, 3\}$ mit $L(w) = (w-2)^2 + (2w-4)^2 + (3w-5)^2$:

w	$(w-2)^2$	$(2w-4)^2$	$(3w-5)^2$	$L(w)$
0	4	16	25	45
0.5	2.25	9	12.25	23.5
1	1	4	4	9
1.5	0.25	1	0.25	1.5
2	0	0	1	1*
2.5	0.25	1	6.25	7.5
3	1	4	16	21

Numerisch gefundenes Minimum: $w_{\text{grid}} = 2$ mit $L(2) = 1$ (mit * markiert).

c) Analytisch. Ausdifferenzieren (Kettenregel):

$$L'(w) = 2(w-2) \cdot 1 + 2(2w-4) \cdot 2 + 2(3w-5) \cdot 3 = 2w - 4 + 8w - 16 + 18w - 30 = 28w - 50.$$

Nullsetzen:

$$28w - 50 = 0 \Rightarrow w^* = \frac{50}{28} = \frac{25}{14} \approx 1.7857.$$

Zweite Ableitung: $L''(w) = 28 > 0$, also Minimum; $w^* \in [0, 3]$ liegt im Intervall. Endpunkte prüfen: $L(0) = 45$ und $L(3) = 21$ sind beide größer – das Minimum auf $[0, 3]$ liegt also tatsächlich bei w^* . Minimaler Loss:

$$L\left(\frac{25}{14}\right) = \left(\frac{25}{14} - \frac{28}{14}\right)^2 + \left(\frac{50}{14} - \frac{56}{14}\right)^2 + \left(\frac{75}{14} - \frac{70}{14}\right)^2 = \frac{9}{196} + \frac{36}{196} + \frac{25}{196} = \frac{70}{196} = \frac{5}{14} \approx 0.3571.$$

Approximationsfehler der Grid Search im Parameter:

$$|w_{\text{grid}} - w^*| = \left|2 - \frac{25}{14}\right| = \frac{3}{14} \approx 0.2143,$$

und im Loss: $|1 - \frac{5}{14}| = \frac{9}{14} \approx 0.6429$. Ein feineres Gitter (kleineres h) würde beide Fehler verkleinern – zum Preis von mehr Auswertungen.