

Übungsblatt 5: Global Optimization (Globale Optimierung)

Begleitmaterial zur Vorlesung „Numerical Methods“ (Prof. Dr.-Ing. Mark Schutera)

Shekel's Foxholes, Newton für Minima, Random Restarts, Basin Hopping und Simulated Annealing (Skript S. 47–56)

13. Juni 2026

Gesamt: 50 Punkte. Hilfsmittel: Taschenrechner. Runden Sie Zwischenergebnisse, sofern nicht anders angegeben, auf mindestens vier Nachkommastellen; bei Endergebnissen genügen zwei bis drei signifikante Nachkommastellen. Die Aufgaben steigen im Schwierigkeitsgrad an: Aufgaben 1–3 prüfen das Begriffsverständnis, Aufgaben 4–7 sind Rechenaufgaben analog zum Skript, Aufgabe 8 ist eine Transferaufgabe. Die Gleichungsnummern (35)–(41) beziehen sich auf das Skript.

Durchgängiges Beispiel: Mehrere Aufgaben verwenden die konkrete 1D-Shekel-Funktion (Shekel's Foxholes) des Skripts [S. 48] mit drei Fuchslöchern (foxholes), ein Spezialfall von Gl. (35), $f(x) = -\sum_{i=1}^m \frac{c_i}{(x-a_i)^2+r_i}$:

$$f(x) = -\frac{1}{(x-0)^2+0.7} - \frac{1.7}{(x-4)^2+0.2} - \frac{1.1}{(x-7)^2+0.4}.$$

Die Funktion besitzt drei Minima bei $x = 0$, $x = 4$ und $x = 7$; das globale Minimum liegt bei $x^* = 4$.

Aufgaben

Aufgabe 1: Lokale versus globale Optimierung

(4 Punkte)

Das Skript unterscheidet [S. 51] die lokale Optimierung (local optimization), Gl. (37),

$$\mathbf{x}^* = \arg \min_{\mathbf{x} \in \mathcal{N}(\mathbf{x}_0)} f(\mathbf{x}), \quad (37)$$

von der globalen Optimierung (global optimization), Gl. (38),

$$\mathbf{x}^* = \arg \min_{\mathbf{x} \in \Omega} f(\mathbf{x}). \quad (38)$$

- (a) Erklären Sie in eigenen Worten den Unterschied zwischen den beiden Problemstellungen. Was bezeichnen $\mathcal{N}(\mathbf{x}_0)$ und Ω ? Geben Sie eine konkrete mengentheoretische Beschreibung einer Nachbarschaft $\mathcal{N}(\mathbf{x}_0)$ an. (2 P)
- (b) Warum kann eine lokale Methode wie Newtons Verfahren das Finden des globalen Minimums nicht garantieren? Belegen Sie Ihre Antwort mit dem Verhalten auf der Shekel-Funktion für die Startpunkte $x_0 = 3$, $x_0 = -2$ und $x_0 = 8$ (qualitativ, ohne Rechnung). (2 P)




Aufgabe 2: Konvexität als Trennlinie (convexity is the dividing line) (6 Punkte)

Eine Funktion f heißt *konvex* (convex), wenn für alle x, y und alle $\lambda \in [0, 1]$ gilt [S. 51]:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

- (a) Warum ist Konvexität die „Trennlinie“ der Optimierung? Was gilt für konvexe Probleme, und welche drei Landschaftsmerkmale machen nicht-konvexe Optimierung laut Skript schwierig? (1 P)
- (b) Zeigen Sie mit der Definition (nicht über die zweite Ableitung), dass $f(x) = x^2$ konvex ist. *Hinweis:* Bringen Sie die Differenz $\lambda f(x) + (1 - \lambda)f(y) - f(\lambda x + (1 - \lambda)y)$ auf eine offensichtlich nichtnegative Form. (2 P)
- (c) Zeigen Sie, dass die Shekel-Funktion (Instanz vom Deckblatt) *nicht* konvex ist, indem Sie die Definition mit $x = 4$, $y = 7$ und $\lambda = \frac{1}{2}$ widerlegen. Werten Sie dazu $f(4)$, $f(7)$ und $f(5.5)$ aus. Formulieren Sie zusätzlich ein allgemeines Argument: Warum kann eine Funktion mit zwei strikten lokalen Minima niemals konvex sein? (3 P)



Aufgabe 3: Basin of Attraction und globale Strategien im Vergleich (5 Punkte)

- (a) Definieren Sie den Begriff *Anziehungsgebiet* (basin of attraction) eines lokalen Minimums im Kontext eines lokalen Optimierers. (1 P)
- (b) Vergleichen Sie die drei globalen Strategien *Random Restarts* (Algorithmus 3 [S. 51]), *Basin Hopping* (Algorithmus 4 [S. 52]) und *Simulated Annealing* [S. 52] hinsichtlich: (i) Wie wird der nächste Startpunkt bzw. Kandidat erzeugt? (ii) Wird Information aus dem bisherigen Suchverlauf weiterverwendet oder die Suche zurückgesetzt? (iii) Nach welchem Kriterium werden Kandidaten akzeptiert? (3 P)
- (c) Was bedeutet der Hyperparameter *Patience* bei der Wahl der Restart-Anzahl K , wenn die Basin-Wahrscheinlichkeit p vorab unbekannt ist? (1 P)



Aufgabe 4: Newton für Minima und der Test der zweiten Ableitung (7 Punkte)

Um mit Newtons Methode Optima zu finden, wird das Optimierungsproblem als Nullstellenproblem auf der Ableitung reformuliert: Wir lösen $f'(x) = 0$ und iterieren nach Gl. (36)/(40):

$$x_{n+1} = x_n - \frac{f'(x_n)}{f''(x_n)}. \quad (40)$$

Newtons Methode, angewandt auf f' , findet dabei Punkte mit $f'(x) = 0^1$ — das können Minima, Maxima oder Sattelpunkte sein. Gegeben sei

$$g(x) = x^3 - 6x^2 + 9x + 1.$$

- (a) Bestimmen Sie $g'(x)$ und $g''(x)$, berechnen Sie alle stationären Punkte ($g'(x) = 0$) analytisch und klassifizieren Sie sie mit dem Test der zweiten Ableitung (second derivative test). Geben Sie auch die Funktionswerte an den stationären Punkten an. Nennen Sie alle drei Fälle des Tests. (3 P)
- (b) Führen Sie ab dem Startpunkt $x_0 = 3.5$ zwei Newton-Schritte nach Gl. (40) aus. Wohin konvergiert das Verfahren offenbar, und um welchen Typ von stationärem Punkt handelt es sich? (2 P)

¹Korrektur zum Originalskript: Auf S. 53 steht versehentlich „Newton’s method finds points where $f''(x) = 0$ “. Sachlich richtig findet das auf f' angewandte Newton-Verfahren Punkte mit $f'(x) = 0$ (Extremstellen); erst der anschließende Test der zweiten Ableitung klassifiziert diese über f'' .

- (c) Führen Sie ab dem Startpunkt $x_0 = 0.5$ einen Newton-Schritt aus. Wohin läuft das Verfahren hier? Was folgt daraus für die Aussage „Newton auf f' findet Minima“? (2 P)




Aufgabe 5: Erfolgswahrscheinlichkeit von Random Restarts

(7 Punkte)

Liegt der Startpunkt mit Wahrscheinlichkeit p im Anziehungsgebiet des globalen Minimums, so gilt für K unabhängige Restarts [S. 51], Gl. (39):

$$P(\text{global gefunden}) = 1 - (1 - p)^K. \quad (39)$$

- (a) **Skript-Rechnung [S. 54]:** Eine Funktion hat fünf lokale Minima; das Basin des globalen Minimums deckt 15 % der Suchdomäne ab ($p = 0.15$). Berechnen Sie die Erfolgswahrscheinlichkeit für $K = 10$ Restarts. (2 P)
- (b) Wie viele Restarts K sind für eine Erfolgswahrscheinlichkeit von 99 % nötig? Leiten Sie zunächst die allgemeine Formel für K aus Gl. (39) her und setzen Sie dann ein. (2 P)
- (c) **Neue Zahlen:** Nun gelte $p = 0.2$. Berechnen Sie (i) die Erfolgswahrscheinlichkeit für $K = 8$ Restarts und (ii) die minimale ganzzahlige Restart-Anzahl K für mindestens 95 % Erfolgswahrscheinlichkeit (Probe nicht vergessen). (2 P)
- (d) **Folgaufgabe des Skripts [S. 55]:** Berechnen Sie K für $p = 0.05$ und $p = 0.01$ bei gleichem 99 %-Ziel. Wie skaliert der Aufwand näherungsweise mit der Basin-Größe p ? (1 P)



Aufgabe 6: Simulated Annealing: Akzeptanzwahrscheinlichkeit

(5 Punkte)

Bei Simulated Annealing [S. 52] wird ein Sprung in eine *schlechtere* Lösung (Verschlechterung $\Delta f > 0$ des Zielfunktionswerts) mit Wahrscheinlichkeit

$$P_{\text{akzeptiert}} = \exp\left(-\frac{\Delta f}{T}\right)$$

akzeptiert, wobei die Temperatur T über die Zeit abnimmt.

(a) Werten Sie die Akzeptanzwahrscheinlichkeit aus für

(i) $\Delta f = 0.5$ bei den Temperaturen $T = 2$, $T = 0.5$ und $T = 0.1$,

(ii) $T = 1$ bei den Verschlechterungen $\Delta f = 0.1$ und $\Delta f = 1.2$.

(3 P)

(b) Diskutieren Sie anhand Ihrer Zahlen den Temperatureffekt: Wie verhält sich der Algorithmus bei hoher bzw. niedriger Temperatur, und warum ist dieses Verhalten (Exploration zu Beginn, Konservativität am Ende) für globale Optimierung sinnvoll? Wie werden Kandidaten mit $\Delta f \leq 0$ (Verbesserungen) behandelt?

(2 P)




Aufgabe 7: Newton Richtung Minima lenken: der $|f''|$ -Trick**(6 Punkte)**

Das Skript schlägt [S. 53] das modifizierte Update vor, Gl. (41):

$$x_{n+1} = x_n - \frac{f'(x_n)}{|f''(x_n)|}. \quad (41)$$

- (a) Erklären Sie, welches Problem des Standard-Updates Gl. (40) der $|f''|$ -Trick behebt. In welchen Regionen der Loss-Landschaft unterscheiden sich die beiden Updates? (1 P)
- (b) Demonstrieren Sie den Unterschied an $f(x) = x^4 - 2x^2$ mit Startpunkt $x_0 = 0.3$: Bestimmen Sie $f'(x)$, $f''(x)$ sowie alle stationären Punkte mit ihrem Typ. Berechnen Sie dann je einen Schritt nach Gl. (40) und nach Gl. (41) und vergleichen Sie die Funktionswerte $f(x_0)$ und $f(x_1)$ für beide Varianten. Welcher Schritt läuft bergab (downhill), welcher bergauf — und wohin würde jede Variante konvergieren? (3 P)
- (c) Was bedeutet der Trick geometrisch für die Schrittrichtung relativ zum Gradienten? Und: *How would you modify the update to find maxima instead?* — Geben Sie ein Update an, das stets in Richtung *wachsender* Funktionswerte läuft, und nennen Sie eine äquivalente Alternative. (2 P)


**Aufgabe 8: Transfer: Newton auf Shekel's Foxholes, Basins und Deep Learning (10 Punkte)**

Betrachten Sie die Shekel-Instanz vom Deckblatt. Für Teilaufgabe (b) dürfen Sie die zweite Ableitung als gegeben verwenden:

$$f''(x) = \frac{2(0.7 - 3x^2)}{(x^2 + 0.7)^3} + \frac{3.4(0.2 - 3(x - 4)^2)}{((x - 4)^2 + 0.2)^3} + \frac{2.2(0.4 - 3(x - 7)^2)}{((x - 7)^2 + 0.4)^3}.$$

- (a) Leiten Sie die erste Ableitung $f'(x)$ her. *Hinweis:* Differenzieren Sie zunächst allgemein einen Summanden $-\frac{c}{(x-a)^2 + r}$ und setzen Sie dann die drei Parametersätze ein. (2 P)
- (b) Werten Sie $f'(7.2)$ und $f''(7.2)$ aus (alle drei Summanden einzeln angeben, dann summieren). (3 P)

- (c) Berechnen Sie den Newton-Schritt x_1 nach Gl. (36)/(40) ab $x_0 = 7.2$. Die weitere Iteration liefert $x_2 \approx 7.02$ und $x_3 \approx 7.00$. Interpretieren Sie das Ergebnis: Wohin konvergiert das Verfahren, und was sagt das über den Startpunkt $x_0 = 7.2$ im Verhältnis zum globalen Minimum $x^* = 4$ aus? (2 P)
- (d) Nehmen Sie an, ein lokaler Optimierer konvergiert stets in das Minimum desjenigen Basins, in dem er startet; die Basin-Grenzen liegen an den lokalen *Maxima* von f , näherungsweise bei $x \approx 1.7$ und $x \approx 5.7$. Geben Sie die Anziehungsgebiete (basins of attraction) der drei Minima $x = 0, 4, 7$ an. Basin Hopping springe nun vom lokalen Minimum $x^\circ = 7$ mit $\delta \sim \text{Uniform}(-3, 3)$: Mit welcher Wahrscheinlichkeit landet ein einzelner Sprung im Basin des globalen Minimums? (2 P)
- (e) Warum kann Basin Hopping hier das globale Minimum schneller finden als Random Restarts? Und der Deep-Learning-Bezug [S. 51]: Warum sind mehrere Trainingsläufe eines neuronalen Netzes mit verschiedenen Seeds *implizite Random Restarts*, und warum ist diese Strategie für große Modelle nicht praktikabel? (1 P)



Lösungen — erst nach Bearbeitung lesen!

Lösung zu Aufgabe 1

(a) Die lokale Optimierung, Gl. (37), sucht das beste $\mathbf{x}$ nur in einer *Nachbarschaft* $\mathcal{N}(\mathbf{x}_0)$ des Startpunkts $\mathbf{x}_0$ — sie findet also dasjenige Minimum, in dessen Einzugsbereich der Startpunkt liegt. Die globale Optimierung, Gl. (38), sucht dagegen über die *gesamte Suchdomäne* Ω und verlangt das beste aller Minima. $\mathcal{N}(\mathbf{x}_0)$ ist eine Menge von Punkten um $\mathbf{x}_0$, z. B. $\mathcal{N}(\mathbf{x}_0) = \{\mathbf{x} : \|\mathbf{x} - \mathbf{x}_0\| < \epsilon\}$ für einen Radius ϵ [Randnotiz S. 51]; Ω ist die gesamte zulässige Suchdomäne, die leicht unendlich groß werden kann.

(b) Lokale Methoden konvergieren zu derjenigen Lösung, die in der Nähe liegt — sie sehen nur Funktionswerte und Gradienten an den ausgewerteten Punkten und können nicht wissen, ob weiter entfernt ein besseres Minimum existiert. Auf der Shekel-Funktion: Von $x_0 = 3$ aus hat man *Glück* und landet im Basin des globalen Minimums $x^* = 4$; von $x_0 = -2$ konvergiert Newton zum lokalen Minimum $x^\circ = 0$, von $x_0 = 8$ zum lokalen Minimum $x^\circ \approx 7$ — das globale Minimum wird in beiden Fällen verfehlt [S. 50]. Selbst mit Konvergenzgarantien garantiert lokale Optimierung also nur das Finden eines *nahen* Extremums.

Lösung zu Aufgabe 2

(a) Für konvexe Probleme ist jedes lokale Minimum zugleich das globale Minimum — jede lokale Methode findet daher das globale Optimum, lokale Verfahren genügen. Die Schwierigkeit entsteht erst bei nicht-konvexer Optimierung: Dort enthält die Landschaft (i) mehrere lokale Minima, (ii) Sattelpunkte (saddle points) und (iii) Plateaus [S. 51].

(b) Für $f(x) = x^2$ betrachten wir die Differenz beider Seiten der Definition:

$$\begin{aligned}\lambda x^2 + (1 - \lambda)y^2 - (\lambda x + (1 - \lambda)y)^2 &= \lambda x^2 + (1 - \lambda)y^2 - \lambda^2 x^2 - 2\lambda(1 - \lambda)xy - (1 - \lambda)^2 y^2 \\ &= \lambda(1 - \lambda)x^2 - 2\lambda(1 - \lambda)xy + (1 - \lambda)(1 - (1 - \lambda))y^2 \\ &= \lambda(1 - \lambda)(x^2 - 2xy + y^2) = \lambda(1 - \lambda)(x - y)^2 \geq 0,\end{aligned}$$

denn $\lambda \in [0, 1]$ impliziert $\lambda(1 - \lambda) \geq 0$ und $(x - y)^2 \geq 0$. Also gilt $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$: x^2 ist konvex.

(c) Auswertung der drei Funktionswerte:

$$\begin{aligned}f(4) &= -\frac{1}{16 + 0.7} - \frac{1.7}{0.2} - \frac{1.1}{9 + 0.4} = -0.0599 - 8.5 - 0.1170 \approx -8.6769, \\ f(7) &= -\frac{1}{49 + 0.7} - \frac{1.7}{9 + 0.2} - \frac{1.1}{0.4} = -0.0201 - 0.1848 - 2.75 \approx -2.9549, \\ f(5.5) &= -\frac{1}{30.25 + 0.7} - \frac{1.7}{2.25 + 0.2} - \frac{1.1}{2.25 + 0.4} = -0.0323 - 0.6939 - 0.4151 \approx -1.1413.\end{aligned}$$

Mit $\lambda = \frac{1}{2}$ verlangt Konvexität

$$f(5.5) \leq \frac{1}{2}f(4) + \frac{1}{2}f(7) = \frac{1}{2}(-8.6769 - 2.9549) \approx -5.8159.$$

Tatsächlich ist aber $f(5.5) \approx -1.1413 > -5.8159$ — Widerspruch, die Shekel-Funktion ist nicht konvex.

Allgemeines Argument: Hätte eine konvexe Funktion zwei strikte lokale Minima $x_1 \neq x_2$, so müsste die Funktion auf der Verbindungsstrecke unterhalb der Sehne bleiben. Zwischen zwei strikten Minima muss die Funktion aber zwingend wieder ansteigen (es existiert ein Punkt dazwischen mit Funktionswert oberhalb beider Minima, ein lokales Maximum), wodurch die Sehnenbedingung dort verletzt wird. Bei konvexen Funktionen ist die Menge der Minimalstellen zusammenhängend (konvex), und jedes lokale Minimum ist global — zwei getrennte strikte lokale Minima sind unmöglich.

Lösung zu Aufgabe 3

(a) Das Anziehungsgebiet (basin of attraction) eines lokalen Minimums ist die Menge aller Startpunkte x_0 , von denen aus der lokale Optimierer zu genau diesem Minimum konvergiert. Die Basin-Grenzen liegen dort, wo die Anziehung von einem Minimum zum nächsten wechselt (bei 1D-Funktionen typischerweise an den lokalen Maxima zwischen den Tälern).

(b) Vergleich der drei Strategien:

	Random Restarts	Basin Hopping	Simulated Annealing
(i) Kandidaten- erzeugung	zufälliger neuer Startpunkt $x_0 \sim$ $\text{RandomPoint}(\Omega)$ aus der gesamten Domäne	zufälliger Sprung $\delta \sim$ $\mathcal{D}$ (z. B. Gauß um null oder uniform) vom zu- letzt gefundenen loka- len Optimum: $x \leftarrow x^* +$ δ	wie Basin Hopping: Sprung vom aktuellen Punkt aus
(ii) Suchverlauf	setzt die Suche kom- plett zurück („com- plete reset“); nur x_{best} wird gemerkt	nutzt den bisherigen Verlauf: Sprünge star- ten beim aktuellen lo- kalen Optimum, lokale Optimierung wird wei- ter ausgenutzt	nutzt den Verlauf wie Basin Hopping
(iii) Akzeptanz	implizit: bestes $f(x^*)$ gewinnt am Ende	bestes $f(x^*)$ wird ge- merkt; jeder Sprung wird ausgeführt	probabilistisch: Ver- besserungen immer; Verslechterungen mit $P = \exp(-\Delta f/T)$, T sinkt über die Zeit

Kernunterschied laut Skript [S. 52]: Basin Hopping erlaubt das Entkommen aus lokalen Minima, während weiterhin lokale Optimierung zum Finden besserer Lösungen genutzt wird; Random Restarts setzt die Suche dagegen vollständig zurück („fühlt sich im Ansatz wieder wie Brute-Forcing an“). Simulated Annealing ergänzt Basin Hopping um das temperaturgesteuerte Akzeptanzkriterium und wird mit sinkender Temperatur zunehmend konservativ, bis nur noch verbessernde Kandidaten akzeptiert werden.

(c) *Patience* kontrolliert, wie viele Restarts ohne Verbesserung der besten gefundenen Lösung abgewartet werden, bevor gestoppt wird: Man erhöht K so lange, bis sich x_{best} stabilisiert (keine Verbesserung nach mehreren aufeinander folgenden Restarts) — eine Heuristik für die Wahl von K , wenn p unbekannt ist [S. 51].

Lösung zu Aufgabe 4

(a) Ableitungen:

$$g'(x) = 3x^2 - 12x + 9 = 3(x-1)(x-3), \quad g''(x) = 6x - 12.$$

Stationäre Punkte: $g'(x) = 0 \Leftrightarrow x = 1$ oder $x = 3$. Test der zweiten Ableitung:

- $x = 1$: $g''(1) = -6 < 0 \Rightarrow$ lokales **Maximum** (Kurve biegt nach unten), $g(1) = 1 - 6 + 9 + 1 = 5$.
- $x = 3$: $g''(3) = 6 > 0 \Rightarrow$ lokales **Minimum** (Kurve biegt nach oben), $g(3) = 27 - 54 + 27 + 1 = 1$.

Die drei Fälle des Tests [S. 53]: $f''(x^*) > 0$ lokales Minimum; $f''(x^*) < 0$ lokales Maximum; $f''(x^*) = 0$ nicht schlüssig (möglicher Sattelpunkt oder Wendepunkt).

(b) Ab $x_0 = 3.5$:

$$g'(3.5) = 3(2.5)(0.5) = 3.75, \quad g''(3.5) = 9 \Rightarrow x_1 = 3.5 - \frac{3.75}{9} = 3.5 - 0.4167 = 3.0833.$$

$$g'(3.0833) = 3(2.0833)(0.0833) = 0.5208, \quad g''(3.0833) = 6.5 \Rightarrow x_2 = 3.0833 - \frac{0.5208}{6.5} = 3.0833 - 0.0801 = 3.0032.$$

Das Verfahren konvergiert offensichtlich gegen $x = 3$, das lokale **Minimum** ($g''(3) = 6 > 0$).

(c) Ab $x_0 = 0.5$:

$$g'(0.5) = 3(-0.5)(-2.5) = 3.75, \quad g''(0.5) = -9 \Rightarrow x_1 = 0.5 - \frac{3.75}{-9} = 0.5 + 0.4167 = 0.9167.$$

Das Verfahren läuft auf $x = 1$ zu — das lokale **Maximum** (ein weiterer Schritt liefert $x_2 \approx 0.9968$). Folgerung: Newton auf f' findet *alle* Punkte mit $f'(x) = 0$, gleichgültig ob Minimum, Maximum oder Sattelpunkt — das Verfahren unterscheidet den Typ nicht. Erst der Test der zweiten Ableitung klassifiziert das Ergebnis; wer gezielt Minima will, braucht z. B. den $|f''|$ -Trick aus Aufgabe 7.

Lösung zu Aufgabe 5

(a) Mit $p = 0.15$ und $K = 10$ [S. 54]:

$$P = 1 - (1 - 0.15)^{10} = 1 - 0.85^{10} = 1 - 0.1969 = 0.803.$$

Etwa 80 % Chance — „not too bad, but far from certain“.

(b) Auflösen von $P = 1 - (1 - p)^K$ nach K : $(1 - p)^K = 1 - P \Rightarrow K \ln(1 - p) = \ln(1 - P)$, also

$$K = \frac{\ln(1 - P)}{\ln(1 - p)} = \frac{\ln(0.01)}{\ln(0.85)} = \frac{-4.6052}{-0.1625} \approx 28.3 \Rightarrow \mathbf{K = 29 \text{ Restarts}} \text{ (aufrunden)}.$$

(c) Mit $p = 0.2$:

(i) $K = 8$: $P = 1 - 0.8^8 = 1 - 0.1678 = 0.832$, also etwa 83 %.

(ii) $K = \frac{\ln(0.05)}{\ln(0.8)} = \frac{-2.9957}{-0.2231} \approx 13.43 \Rightarrow K = 14$.

Probe: $1 - 0.8^{14} = 1 - 0.0440 = 0.956 \geq 0.95 \checkmark$, während $K = 13$ nur $1 - 0.8^{13} = 0.945 < 0.95$ liefert.

(d) Bei gleichem 99 %-Ziel:

$$p = 0.05 : K = \frac{\ln(0.01)}{\ln(0.95)} = \frac{-4.6052}{-0.0513} \approx 89.8 \Rightarrow K = 90, \quad p = 0.01 : K = \frac{\ln(0.01)}{\ln(0.99)} = \frac{-4.6052}{-0.0101} \approx 458.2 \Rightarrow K$$

Wegen $\ln(1 - p) \approx -p$ für kleine p gilt $K \approx \ln(1 - P)^{-1} \cdot \text{konstant}/p$, d. h. der Aufwand skaliert näherungsweise mit $1/p$: Halbiert sich das Basin des globalen Minimums, verdoppelt sich (ungefähr) die nötige Restart-Anzahl. In der Praxis ist p unbekannt — dann hilft die Patience-Heuristik aus Aufgabe 3(c).

Lösung zu Aufgabe 6

(a) Auswertung von $P = \exp(-\Delta f/T)$:

Δf	T	$-\Delta f/T$	$P_{\text{akzeptiert}}$
0.5	2	-0.25	$e^{-0.25} \approx 0.779$
0.5	0.5	-1	$e^{-1} \approx 0.368$
0.5	0.1	-5	$e^{-5} \approx 0.0067$
0.1	1	-0.1	$e^{-0.1} \approx 0.905$
1.2	1	-1.2	$e^{-1.2} \approx 0.301$

(b) *Temperatureffekt*: Bei hoher Temperatur ($T = 2$) wird dieselbe Verschlechterung $\Delta f = 0.5$ mit $\approx 78\%$ akzeptiert, bei $T = 0.1$ nur noch mit $\approx 0.7\%$ — der Algorithmus ist anfangs *explorativ* (springt häufig auch in schlechtere Lösungen und kann so Basins lokaler Minima verlassen) und wird mit sinkender Temperatur zunehmend *konservativ*, bis er praktisch nur noch verbessernde Kandidaten akzeptiert und zu einem Optimum konvergiert [S. 52]. Außerdem zeigt die zweite Tabellenhälfte: Bei fester Temperatur werden *kleine* Verschlechterungen ($\Delta f = 0.1$: $\approx 90\%$) viel eher akzeptiert als große ($\Delta f = 1.2$: $\approx 30\%$). Verbesserungen ($\Delta f \leq 0$) werden stets akzeptiert (formal wäre $\exp(-\Delta f/T) \geq 1$). Dieses Schema balanciert Exploration (global suchen, solange T hoch) und Exploitation (lokal verfeinern, wenn T klein) — genau das, was globale Optimierung braucht.

Lösung zu Aufgabe 7

(a) Das Standard-Update Gl. (40) sucht Nullstellen von f' — es konvergiert daher genauso bereitwillig zu Maxima und Sattelpunkten wie zu Minima (vgl. Aufgabe 4(c)). Die beiden Updates unterscheiden sich genau dort, wo $f''(x_n) < 0$ ist (konkave Regionen, z. B. in der Nähe lokaler Maxima): Dort kehrt Gl. (41) das Vorzeichen des Schritts um. Wo $f''(x_n) > 0$ gilt, sind beide Updates identisch.

(b) $f(x) = x^4 - 2x^2$, also $f'(x) = 4x^3 - 4x = 4x(x-1)(x+1)$ und $f''(x) = 12x^2 - 4$. Stationäre Punkte: $x = 0$ mit $f''(0) = -4 < 0$ (lokales **Maximum**, $f(0) = 0$) sowie $x = \pm 1$ mit $f''(\pm 1) = 8 > 0$ (globale **Minima**, $f(\pm 1) = -1$).

Am Startpunkt $x_0 = 0.3$:

$$f'(0.3) = 4(0.027) - 1.2 = -1.092, \quad f''(0.3) = 12(0.09) - 4 = -2.92 < 0.$$

Standard-Newton, Gl. (40):

$$x_1 = 0.3 - \frac{-1.092}{-2.92} = 0.3 - 0.3740 = -0.0740.$$

Funktionswerte: $f(0.3) = 0.0081 - 0.18 = -0.1719$, aber $f(-0.0740) \approx 0.00003 - 0.01095 = -0.0109$. Der Funktionswert ist *gestiegen*: Der Schritt läuft bergauf, direkt auf das lokale Maximum $x = 0$ zu — dorthin würde Standard-Newton konvergieren.

Mit $|f''|$, Gl. (41):

$$x_1 = 0.3 - \frac{-1.092}{|-2.92|} = 0.3 + 0.3740 = 0.6740.$$

Funktionswert: $f(0.6740) \approx 0.2063 - 0.9085 = -0.7022 < -0.1719$. Der Schritt läuft bergab in Richtung des Minimums $x = 1$ — dorthin würde die modifizierte Iteration konvergieren.

(c) *Geometrie*: Da $|f''(x_n)| > 0$, hat der Schritt $-f'(x_n)/|f''(x_n)|$ stets das *entgegengesetzte* Vorzeichen zu $f'(x_n)$ — er zeigt also immer in Richtung des negativen Gradienten („downhill so to speak“), während die Krümmung nur noch die Schrittweite skaliert. So bewegen wir uns garantiert in Richtung abnehmender Funktionswerte $f(x)$ [S. 53]. Für die Tangentenkonstruktion an f' bedeutet das: In konkaven Regionen wird die Steigung der Tangente am Graphen von f' effektiv am Vorzeichen gespiegelt, sodass der Schnittpunkt mit der x -Achse auf der bergab gelegenen Seite gesucht wird.

Maxima statt Minima: Vorzeichen des Schritts umdrehen,

$$x_{n+1} = x_n + \frac{f'(x_n)}{|f''(x_n)|},$$

dann läuft die Iteration stets in Richtung des *positiven* Gradienten (bergauf, hill climbing). Äquivalente Alternative: Gl. (41) unverändert auf $-f$ anwenden, denn Maxima von f sind Minima von $-f$.

Lösung zu Aufgabe 8

(a) Für einen allgemeinen Summanden gilt mit Ketten- und Potenzregel:

$$\frac{d}{dx} \left[-\frac{c}{(x-a)^2 + r} \right] = -c \cdot \frac{d}{dx} ((x-a)^2 + r)^{-1} = \frac{2c(x-a)}{((x-a)^2 + r)^2}.$$

Einsetzen der drei Parametersätze $(a, c, r) = (0, 1, 0.7)$, $(4, 1.7, 0.2)$, $(7, 1.1, 0.4)$:

$$f'(x) = \frac{2x}{(x^2 + 0.7)^2} + \frac{3.4(x-4)}{((x-4)^2 + 0.2)^2} + \frac{2.2(x-7)}{((x-7)^2 + 0.4)^2}.$$

(b) Erste Ableitung bei $x = 7.2$ (Summanden einzeln):

$$\frac{2 \cdot 7.2}{(51.84 + 0.7)^2} = \frac{14.4}{2760.45} \approx 0.0052, \quad \frac{3.4 \cdot 3.2}{(10.24 + 0.2)^2} = \frac{10.88}{108.99} \approx 0.0998, \quad \frac{2.2 \cdot 0.2}{(0.04 + 0.4)^2} = \frac{0.44}{0.1936} \approx 2.2727$$

$$f'(7.2) \approx 0.0052 + 0.0998 + 2.2727 = 2.3777 \approx 2.38.$$

(Das Skript [S. 49] schreibt $0.005 + 0.100 + 2.27 = 2.38$; die gerundeten Summanden ergeben arithmetisch 2.375, die Rundung auf 2.38 ist zulässig und konsistent mit dem exakten Wert 2.3778.)

Zweite Ableitung bei $x = 7.2$ (Summanden einzeln):

$$\frac{2(0.7 - 155.52)}{52.54^3} = \frac{-309.64}{145034} \approx -0.0021, \quad \frac{3.4(0.2 - 30.72)}{10.44^3} = \frac{-103.768}{1137.89} \approx -0.0912, \quad \frac{2.2(0.4 - 0.12)}{0.44^3} = \frac{0.56}{0.085184} \approx 6.574$$

$$f''(7.2) \approx -0.0021 - 0.0912 + 6.574 = 6.4807 \approx 6.48.$$

(c) Newton-Schritt nach Gl. (36)/(40):

$$x_1 = 7.2 - \frac{f'(7.2)}{f''(7.2)} = 7.2 - \frac{2.3777}{6.4807} = 7.2 - 0.3653 \approx 6.83.$$

Mit $x_2 \approx 7.02$ und $x_3 \approx 7.00$ konvergiert das Verfahren zum *lokalen* Minimum $x^\circ \approx 7$ (dort ist $f'' > 0$, der dritte Summand dominiert). Interpretation: Der Startpunkt $x_0 = 7.2$ liegt im Anziehungsgebiet des Fuchslochs bei $x = 7$ — „Here, we were unlucky, and the method is attracted to the nearby foxhole at $x^\circ \approx 7$ “ [S. 50]. Das globale Minimum $x^* = 4$ wird verfehlt, obwohl es deutlich tiefer liegt ($f(4) \approx -8.68$ gegenüber $f(7) \approx -2.95$, vgl. Aufgabe 2(c)): Lokale Optimierung garantiert nur das Finden eines nahen Extremums.

(d) Da der Optimierer stets in das Minimum seines Start-Basins konvergiert und die lokalen Maxima die Basin-Grenzen bilden, gilt näherungsweise:

$$B(0) = (-\infty, 1.7), \quad B(4) = (1.7, 5.7), \quad B(7) = (5.7, \infty).$$

Das Basin des globalen Minimums $x^* = 4$ ist das mittlere Intervall. Ein Sprung von $x^\circ = 7$ mit $\delta \sim \text{Uniform}(-3, 3)$ landet gleichverteilt in $[4, 10]$ (Länge 6). Der Überlapp mit $B(4) = (1.7, 5.7)$ ist $[4, 5.7)$ mit Länge 1.7, also

$$P = \frac{5.7 - 4}{6} = \frac{1.7}{6} \approx 0.283 \approx 28\%.$$

(e) *Basin Hopping vs. Random Restarts*: Basin Hopping startet seine Sprünge vom bereits gefundenen lokalen Optimum und nutzt damit die Struktur der Landschaft: Von $x^\circ = 7$ aus erreicht schon ein einzelner Sprung mit $\approx 28\%$ Wahrscheinlichkeit das Basin des globalen Minimums — die Foxholes liegen nahe beieinander, die Sprungverteilung muss nur die Distanz zum Nachbar-Basin überbrücken. Random Restarts sampelt dagegen gleichverteilt aus der gesamten (potenziell sehr großen) Domäne Ω ; ist Ω groß, wird die Trefferwahrscheinlichkeit p pro Restart

klein, und jede Wiederholung verwirft zudem alle bisherige Information (vollständiger Reset). *Deep-Learning-Bezug* [S. 51]: Jeder Trainingslauf eines neuronalen Netzes mit anderem Seed startet von einer anderen zufälligen Initialisierung der Gewichte — das ist genau ein zufälliger Startpunkt $x_0 \in \Omega$ mit anschließender lokaler Optimierung (SGD/Adam), also implizite Random Restarts; am Ende behält man das Modell mit dem besten Loss. Für große Modelle ist das nicht praktikabel, weil schon ein einzelner Trainingslauf enorm teuer ist — man verlässt sich stattdessen auf die Hoffnungen aus dem Skript [S. 53]: Die meisten lokalen Minima sind etwa gleich gut, Überparametrisierung macht schlechte Minima selten, Mini-Batch-Rauschen hilft beim Entkommen aus scharfen Minima, adaptive Lernraten helfen auf Plateaus.