

Optimierungsverfahren


Teil 02 - Grundlagen

Martin Zaefferer

Grundlagen


Beispiel: Optimierungsprobleme

- Routing / Kürzester Pfad



Beispiel: Optimierungsprobleme

- Optimierung der Tragflächenform



airfoils, cross-sections of wings or rotor blades
objectives: drag / lift / weight / ...

Beispiel: Training von ML Modellen

- Immer wenn in Statistik oder Machine Learning ein Modell an Daten angepasst wird: Optimierung!
 - z.B.: Optimierung der Gewichte von Neuronalen Netzen
 - z.B.: Bestimmen der Koeffizienten eines linearen Regressionsmodelles

Beispiel: Tuning von Machine Learning Modellen

- Optimierung der Hyperparameter von ML Modellen
 - z.B.: Bestimmen der Anzahl Neuronen / Schichten eines Neuronalen Netzes
 - z.B.: Bestimmen der Anzahl Bäume für Random Forest


Beispiel: In der Natur

- Nicht nur Optimierung in Alltag & Technik des Menschen
- Verhalten von Lebewesen
 - Tierschwärme die Nahrungsquellen suchen (Vögel, Bienen)
 - Ausrichtung von Pflanzen zur Sonne
- Optimale Anpassung von Lebewesen an ihre Umgebung (Evolution)
- Auch implizit in der Physik (z.B. Minimierungsprinzip der inneren Energie)

Problemdefinition

- Variablen
- Parameter
- Funktionen
 - Zielfunktion(en)
 - Nebenbedingungen / Restriktionen
 - Gleichung
 - Ungleichung
- gezielt variiert (Entscheidung)
- nicht gezielt variiert (Umgebung)
- Mathematisches Modell des Problems
 - Qualitätsmaß von Lösungskandidaten
 - Einschränkung zulässiger Lösungen
 - Müssen exakt zutreffen
 - Größere oder kleinere Werte erlaubt


Problemdefinition: Routing



Kürzester Weg von A nach B

- Variablen
 - Parameter
 - Funktionen
 - Zielfunktion(en)
 - Nebenbedingungen
 - Gleichung
 - Ungleichung
- welche Straßen genutzt werden
 - Verkehrsdichte, Start/Zielort
 - - Reisedauer, Reisekosten, ...
 -
 - Verfügbarer Kraftstoff

Problemdefinition: Tragflächen



Suche nach bester Tragflächenform

- Variablen
- Parameter
- Funktionen
 - Zielfunktion(en)
 - Nebenbedingungen
 - Gleichung
 - Ungleichung
- Form der Tragflächen (Länge, Breite, ...)
- Maße des Flugzeuges, Geschwindigkeiten
- - Luftwiderstand und Auftrieb
 -
 - Herstellungskosten, Gewicht, ...

Problemdefinition: Mathematische Notation

- Variablen
 - n Variablen $\vec{x} = x_1, \dots, x_n$
- Parameter
 - q Parameter $\vec{p} = p_1, \dots, p_q$
- Funktionen
 - - Zielfunktion(en)
 - $y = f(\vec{x})$ oder auch $\vec{y} = f(\vec{x})$
 - Nebenbedingungen
 - Gleichung
 - l Gleichungsnebenbedingung $h_k(\vec{x})$
 - Ungleichung
 - m Ungleichungsnebenbedingung $g_j(\vec{x})$

Problemdefinition: weitere wichtige Begriffe

- $\vec{x}$: Lösungskandidat*
- $\mathcal{X}$: Suchraum, Menge aller Lösungskandidaten**, $\vec{x}$ in $\mathcal{X}$
 - Beispiel: Suchraum mit n reellen Variablen $\mathcal{X} = \mathbb{R}^n$
- $\mathcal{X}_z$: Zulässiger Bereich, Untermenge von $\mathcal{X}$, nur zulässige Lösungen (Nebenbedingungen)
 - Beispiel n Variablen mit Grenz-Nebenbedingungen
 $\mathcal{X}_z = [l_1, u_1] \times [l_2, u_2] \times \dots \times [l_n, u_n]$
- $\mathcal{Y}$: Zielraum
 - Beispiel: Eine ganzzahlige Zielfunktion $\mathcal{Y} = \mathbb{Z}$
 - Beispiel: Optimierung mit 3 reellen Zielen $\mathcal{Y} = \mathbb{R}^3$

*: manchmal auch Lösung / Lösungsvektor / Punkt


** : beinhaltet manchmal keine unzulässigen Lösungen, d.h., $\mathcal{X} = \mathcal{X}_z$

Problemdefinition: Mathematische Notation

$$\begin{array}{ll} \text{minimiere} & f(\vec{x}) \\ \text{mit} & h_k(\vec{x}) = 0, \quad k = 1, 2, \dots, l \\ & g_j(\vec{x}) \leq 0, \quad j = 1, 2, \dots, m \\ & x_i^l \leq x_i \leq x_i^u, \quad i = 1, 2, \dots, n \end{array}$$

Beispiel: Getränkedose

- Minimiere Materialkosten
- Vorgegebenes Volumen: 0.5 l
- Ästhetische Anforderung: h soll mindestens doppelt so groß sein wie d
- Materialkosten: $C = 0.01 \text{ €/cm}^2$
- Durchmesser zwischen 6 und 9 cm, Höhe zwischen 12 und 18 cm
- Vereinfachende Annahmen
 - Kosten des Bodens und des Deckels vernachlässigen
 - Materialstärke vernachlässigen



Beispiel: Getränkedose

$$\begin{array}{ll} \text{minimiere} & f(d, h) : C\pi dh \\ & \text{mit} \\ & h_1(d, h) : \pi d^2 h / 4 - 500 = 0 \\ & g_1(d, h) : 2d - h \leq 0 \\ & 6 \leq d \leq 9 \ ; \ 12 \leq h \leq 18 \end{array}$$

Beispiel: Getränkedose

- Suchraum $\mathcal{X} = \mathbb{R}^2$
- Zulässiger Bereich $\mathcal{X}_z = \{\vec{x} | (\vec{x} \in [6, 9] \times [12, 18]) \wedge (h_1(\vec{x}) = 0) \wedge (g_1(\vec{x}) \leq 0)\}$

Lokal vs. Global

Globale Extrema

Folgendes gilt insbesondere für *eine* Zielfunktion, bzw. $f(\vec{x}) = y \in \mathbb{R}$. Mehrere Zielfunktionen behandeln wir erst später


- Globales Minimum bei $\vec{x}^*$:
 $f(\vec{x}^*) \leq f(\vec{x})$ für alle $\vec{x} \in \mathcal{X}_z$
 - d.h. es gibt keinen kleineren Wert y als das globale Minimum bei $\vec{x}^*$
- Globales Maximum bei $\vec{x}^*$:
 $f(\vec{x}^*) \geq f(\vec{x})$ für alle $\vec{x} \in \mathcal{X}_z$
 - d.h. es gibt keinen größeren Wert y als das globale Maximum bei $\vec{x}^*$

Nachbarschaft, Lokale Extrema

- Nachbarschaft $\mathcal{N}(\vec{x})$:
Menge aller **zulässigen** (!) Lösungskandidaten "nahe" $\vec{x}$.
 - Hängt von der Art der Variablen ab (Ist $\vec{x} \in \mathbb{R}^n$? Oder ist $\vec{x} \in \mathbb{Z}^n$? Oder ist $\vec{x}$ ein Pfad durch einen Graph?)
- Lokales Minimum bei $\vec{x}^*$:
 $f(\vec{x}^*) \leq f(\vec{x})$ für alle $\vec{x} \in \mathcal{N}(\vec{x}^*)$
 - d.h. es gibt keinen kleineren Wert y in der unmittelbaren Nachbarschaft von $\vec{x}^*$ als das lokale Minimum bei $\vec{x}^*$
- Lokales Maximum bei $\vec{x}^*$:
 $f(\vec{x}^*) \geq f(\vec{x})$ für alle $\vec{x} \in \mathcal{N}(\vec{x}^*)$
 - d.h. es gibt keinen größeren Wert y in der unmittelbaren Nachbarschaft von $\vec{x}^*$ als das lokale Maximum bei $\vec{x}^*$

Anmerkung: hier berücksichtigen wir auch nur $\vec{x} \in \mathcal{X}_z$





Lokal / Global



Unimodale / Multimodale Probleme

- Nur ein Optimum:
Problem ist *unimodal*
- Mehrere Optima (lokal und global):
Problem ist *multimodal*

Unimodal / Multimodal



Lokale / Globale Optimierungsalgorithmen

- Algorithmus kann nur unimodale Problem lösen
 - *lokaler* Algorithmus
- Algorithmus kann auch multimodale Problem lösen:
 - *globaler* Algorithmus
- Achtung: die Trennung ist in der Praxis nicht immer ganz so eindeutig. (Graubereich, Umwandlung lokale in globale Algorithmen)

Frage:

- Wie viele globale Minima kann ein Problem haben?
- ... und wie viele lokale?





Weitere Eigenschaften von Algorithmen / Problemen

Eigenschaften von Algorithmen / Problemen

Eigenschaft	Algorithmen	Probleme
Modalität	lokal / global	unimodal / multimodal
Differenzierbarkeit	gradientenbasiert / gradientenfrei	differenzierbar / nicht diff.
Nebenbedingungen	ohne / gleich / ungleich	ohne / gleich / ungleich
Ziele	eines / mehrere	eines / mehrere
Linearität	linear / nicht-linear	linear / nicht-linear
Lösungsansatz	analytisch / numerisch	/
Genauigkeit	exakt / approximativ	/
Zufallseinfluss	deterministisch / stochastisch	deterministisch / stochastisch
Variablen	diskret / kombinatorisch / kontinuierlich (reell) / gemischt	dis. / kom. / kon. / gem.

Eigenschaft: Linear vs. Nichtlinear

- Linearität von aller Funktionen (Zielfunktion und Nebenbedingungen)
- Spezialisierte Algorithmen



Analytisch vs. Numerisch

- Analytische Lösung: Rechnen mit mathematischen Symbolen, Äquivalenzumformungen, ohne Annäherung
 - Beispiel aus Mathe: Nullstellen bestimmen über Gauss-Umformungen
- Numerische Lösung: Schrittweise / Approximativ
 - Beispiel aus Mathe: Nullstellen bestimmen über Newton Verfahren

Eigenschaften: Exakt vs. Approximativ

- Eigenschaft von Algorithmen
 - Exakt: Lösung wird exakt bestimmt
 - Approximativ: Ungefähre, approximative Lösung, möglicherweise nicht optimal (lokal oder global)
- Exakte Algorithmen müssen nicht analytisch sein, bzw. können auch numerisch sein
 - Beispiel: brute force

Eigenschaften: Deterministisch vs. Stochastisch

- Algorithmeigenschaft
 - Deterministisch: Algorithmus hat keine zufällige Komponente (e.g., Gradient Descent, DIRECT)
 - stochastisch: Algorithmus hat zufällige Komponente (e.g., Evolutionäre Algorithmen)
- Problemeigenschaft
 - Deterministisch: kein Rauschen
 - stochastisch: Rauschen (in Variablen, Funktionen, Umgebungseinflüsse, ...)

Eigenschaften: Diskret vs. Kontinuierlich


- Kontinuierlich: $\vec{x} \in \mathbb{R}^n$
- Diskret/kombinatorisch: Variablen $\vec{x}$ sind Integer, Permutationen, Graphen, Strings, Binär, ...

Eigenschaften

- Frage: Eigenschaften des 3-Hump Problems?

$$f_{3\text{hump}}(\vec{x}) = 2x_1^2 - 1.05x_1^4 + x_1^6/6 + x_1x_2 + x_2^2$$

- Erinnerung:
 - Unimodal / multi-modal
 - Differenzierbar?
 - Nebenbedingungen: keine / gleich / ungleich
 - Einzel / mehrziel
 - Linear / nichtlinear
 - Deterministisch / stochastisch
 - Diskret / kontinuierlich / gemischt



Gradienten und stationäre Punkte

Analytische Lösung

- Im folgenden versuchen wir erstmal *analytisch* zu lösen
 - Alternativ wäre ein *numerischer* Lösungsansatz, dazu kommen wir später
- Hier: Für *nichtlineare Optimierung*, ohne Nebenbedingungen

Gradient

- Gradient von f

$$\nabla f(\vec{x}) = \begin{bmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{bmatrix}$$

- Vektor der partiellen Ableitungen
- Deutet in Richtung des stärksten Anstiegs

Stationäre Punkte

- Kennen Sie vielleicht noch aus Schulmathematik oder Vorlesung im ersten Semester
- f hat stationären Punkt (SP) bei $\vec{x}$ wenn

$$\nabla f(\vec{x}) = \vec{0}$$

- Lokale Minima und Maxima sind SP
- Sattelpunkte sind auch SP

Frage: $\nabla f(\vec{x}) = \vec{0}$ sieht aus wie ein Gleichungssystem. Können wir das mit Gaußsumformungen lösen?

Notwendige Bedingung für Optima

- Berechne SP
 - Setzt voraus, dass $\nabla f(\vec{x})$ verfügbar/berechenbar ist
- Löse nach $\vec{x}$: $\nabla f(\vec{x}) = \vec{0}$
 - Setzt Lösbarkeit voraus
- Lösungen sind *mögliche* lokale Optima

Frage:

- Können Sie sich Probleme vorstellen, bei denen $\nabla f(\vec{x})$ nicht verfügbar oder berechenbar ist?

Ausreichende Bedingung

- Nicht alle SP sind lokale Optima
- SP: notwendig, nicht ausreichend
- Ausreichende Bedingung: Hessematrix bei SP:


$$\mathbf{H}(\vec{x}_{\text{SP}}) = \nabla^2 f(\vec{x}_{\text{SP}}) = \begin{bmatrix} \partial^2 f / \partial x_1^2 & \partial^2 f / \partial x_2 x_1 & \dots & \partial^2 f / \partial x_n x_1 \\ \vdots & \vdots & \dots & \vdots \\ \partial^2 f / \partial x_1 x_n & \partial^2 f / \partial x_2 x_n & \dots & \partial^2 f / \partial x_n^2 \end{bmatrix}$$

Ausreichende Bedingung: Hessematrix

- **H** Positiv definit (alle Eigenwerte positiv) $\rightarrow$ lokales Minimum
- **H** Negativ definit (alle Eigenwerte negativ) $\rightarrow$ lokales Maximum
- **H** Indefinit (gemischte Vorzeichen) $\rightarrow$ Sattelpunkt
- Semi-definit (nur positiv / nur negativ aber beinhaltet Null) $\rightarrow$ uneindeutig! (in diesem Fall: Bedingung nicht ausreichend)


Beispiel: Positiv Definit

- $f(\vec{x}) = x_1^2 + x_2^2$
- $\nabla f(\vec{x}) = ?$
- SP bei $[x_1 = ?, x_2 = ?]$
- $\mathbf{H} = \begin{bmatrix} ? & ? \\ ? & ? \end{bmatrix}$
- Eigenwerte: $\lambda_1 = ?$,
 $\lambda_2 = ?$




Beispiel: Positiv Definit

- $f(\vec{x}) = x_1^2 + x_2^2$
- $\nabla f(\vec{x}) = \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix}$
- SP bei $(x_1 = 0, x_2 = 0)$
- $\mathbf{H} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$
- Eigenwerte: $\lambda_1 = 2$,
 $\lambda_2 = 2$




Beispiel: Indefinit

- $f(\vec{x}) = x_1^2 + x_2^2 - 5x_1x_2$
- $\nabla f(\vec{x}) = \begin{pmatrix} 2x_1 - 5x_2 \\ 2x_2 - 5x_1 \end{pmatrix}$
- SP bei $[x_1 = 0, x_2 = 0]$
- $\mathbf{H} = \begin{bmatrix} 2 & -5 \\ -5 & 2 \end{bmatrix}$
- Eigenwerte: $\lambda_1 = 7$,
 $\lambda_2 = -3$



Beispiel: Positiv Semi-Definit

- $f(\vec{x}) = x_1^2 + x_2^2 - 2x_1x_2$
- $\nabla f(\vec{x}) = \begin{pmatrix} 2x_1 - 2x_2 \\ 2x_2 - 2x_1 \end{pmatrix}$
- SP sind alle Punkte mit $x_1 = x_2$
- $\mathbf{H} = \begin{bmatrix} 2 & -2 \\ -2 & 2 \end{bmatrix}$
- Eigenwerte: $\lambda_1 = 4$,
 $\lambda_2 = 0$



Überblick

Eigenschaften von Algorithmen/Methoden

Methode	Global	Gradientenbasiert	Nebenbedingungen	Ziele	Linear	Ansatz	Genauigkeit	Deterministisch	Variablen
Stationäre Punkte / Hesse	✓	✓	ohne	1	✗	analytisch	exakt	✓	$\mathbb{R}^n$

Algorithmus: Gradient Descent

Gradient Descent

- Numerischer, nicht analytischer Ansatz
- Braucht Gradient der Zielfunktion
- Anwendung im Machine Learning:
 - Insbesondere häufig zur Optimierung neuronaler Netze (in verschiedenen Varianten)

Gradient Descent

1. Setze Startlösung $\vec{x}_{i=0}$
 2. Berechne den Gradienten $\nabla(\vec{x}_i)$
 3. Wenn Gradient $\nabla(\vec{x}_i) \approx [0, \dots, 0]^T$: beenden
 4. Sonst: Bewegung in Richtung des Gradienten mit $\vec{x}_{i=i+1} = \vec{x}_i - c \cdot \nabla(\vec{x}_i)$, wobei c ein Parameter des Algorithmus ist
 5. Gehe zu 2
- Eigenschaften von Gradient Descent: unbegrenzt / keine Nebenbedingungen, lokal, gradientenbasiert, deterministisch (wenn $\vec{x}_{i=0}$ festliegt), einziel, kontinuierlich, nichtlinear.
 - Siehe Buch von Venkataraman, Chapter 5 für ein paar weitere Details bzw. möglichen Ergänzungen zu Schritt 4.

Beispiel: Gradient Descent, 3-Hump function

- 3 Hump Function

$$f_{3\text{hump}}(\vec{x}) = 2x_1^2 - 1.05x_1^4 + x_1^6/6 + x_1x_2 + x_2^2$$

$$\nabla f_{3\text{hump}}(\vec{x}) = \begin{bmatrix} ? \\ ? \end{bmatrix}$$


Beispiel: Gradient Descent, 3-Hump function

- 3 Hump Function


$$f_{3\text{hump}}(\vec{x}) = 2x_1^2 - 1.05x_1^4 + x_1^6/6 + x_1x_2 + x_2^2$$

$$\nabla f_{3\text{hump}}(\vec{x}) = \begin{bmatrix} 4x_1 - 4.2x_1^3 + x_1^5 + x_2 \\ x_1 + 2x_2 \end{bmatrix}$$


Beispiel: Gradient Descent, 3-Hump function




Beispiel: Gradient Descent, 3-Hump function



Beispiel: Gradient Descent, 3-Hump function





Beispiel: Gradient Descent, 3-Hump function



Gradient Descent

- Problem: Falsche Schrittweite führt zu Oszillation, langsamer Konvergenz zum Minimum
- Effizienter: Quasi Newton, BFGS, Truncated Newton, CG, Momentum, ...



Gradient Descent

- Warum ist Gradient Descent wichtig für Data Scientists?
 - Grundlage für Training von ML Modellen, insbes. Neuronale Netze
 - Meist mit wichtigen Anpassungen / Voraussetzungen z.B.:
 - *Stochastische* Approximation des Gradienten (Stochastic Gradient Descent)
 - *Momentum* ('Impulserhaltung') / Nesterov-Momentum
 - Algorithmus: ADAM

Überblick

Eigenschaften von Algorithmen/Methoden

Methode	Global	Gradientenbasiert	Nebenbedingungen	Ziele	Linear	Ansatz	Genauigkeit	Deterministisch	Variablen
Stationäre Punkte / Hesse	✓	✓	ohne	1	✗	analytisch	exakt	✓	$\mathbb{R}^n$
Gradient Descent	✗	✓	ohne	1	✗	numerisch	?	✓	$\mathbb{R}^n$

Anwendungsbeispiel in R

- AnwendungOV-02-GradDesc.Rmd
- Verstehen wie das Beispiel funktioniert
- Anpassen des Beispiels: Gradient Descent zur Lösung des 3-hump Problems