

Optimierungsverfahren

Teil 04 - Nicht-Linear

Martin Zaefferer

Einführung: Quadratische Optimierung

Quadratische Optimierung (QO)

- Quadratische Zielfunktion
- Lineare Nebenbedingungen

$$\begin{array}{ll}\text{minimiere} & f(\vec{x}) : \frac{1}{2} \vec{x}^T \mathbf{Q} \vec{x} + \vec{c}^T \vec{x} \\ \text{mit} & g(\vec{x}) : \mathbf{A} \vec{x} \leq \vec{b} \\ & h(\vec{x}) : \mathbf{A}_{\text{eq}} \vec{x} = \vec{b}_{\text{eq}} \\ & b_{\text{lower}} \leq x_i \leq b_{\text{upper}}\end{array}$$

Frage

Ist das Dosen-Beispiel ein QO-Problem?

minimiere
 d, h


$$f(d, h) : C\pi dh$$

mit

$$h_1(d, h) : \pi d^2 h / 4 - 500 = 0$$

$$g_1(d, h) : 2d - h \leq 0$$

$$6 \leq d \leq 9 ; 12 \leq h \leq 18$$



Eigenschaften von $\mathbf{Q}$

- $\mathbf{Q}$ sollte symmetrisch sein

$$\mathbf{Q} = \mathbf{Q}^T$$

- $\mathbf{Q}$ sollte häufig positiv (semi)-definit sein für Standard-Solver
 - Erinnerung: positiv semi-definit bedeutet keine negativen Eigenwerte
- Positiv definit: Konvexes Problem, eindeutige Lösung

$$\begin{array}{ll} \underset{\vec{x}}{\text{minimiere}} & f(\vec{x}) : \frac{1}{2} \vec{x}^T \mathbf{Q} \vec{x} + \vec{c}^T \vec{x} \\ \text{mit} & g(\vec{x}) : \mathbf{A} \vec{x} \leq \vec{b} \\ & h(\vec{x}) : \mathbf{A}_{\text{eq}} \vec{x} = \vec{b}_{\text{eq}} \\ & b_{\text{lower}} \leq x_i \leq b_{\text{upper}} \end{array}$$

QO Algorithmen

- Interior-point Algorithmen
- Conjugate Gradient
- Variationen des Simplex Algorithmus (siehe lineare Optimierung, Simplex)
- Augmented Lagrangian
- Wahl hängt von Problemdefinition ab (Konvexität, Nebenbedingungen, ...)
- Verschiedene R Implementationen: <https://cran.r-project.org/view=Optimization>

Implementationen

- Insbesondere für komplexere QO probleme: Auswahl der Algorithmen / Konfiguration wird schwieriger
- Kommerzielle Solver lösen das relativ gut
 - z.B.: IBM's CPLEX, GUROBI optimizer
- Hyper-heuristics (Heuristische Auswahl von Solvern)
 - siehe auch Dunning et al. 2018
(https://github.com/MQLib/MQLib/blob/master/paper/SECM_final.pdf) (betrifft QOBO, nicht generell QO)

QO Anwendungen: Konvex mit Nebenbedingungen

- **Curve fitting, least squares**
- Optimal control / model predictive control
- Portfolio Optimierung
- Clustering, Feature Selection
- Support Vector Machines

Constrained Least Squares Regression

Constrained Least Squares Regression

- Lineare Regression, aber mit Nebenbedingungen
- Problem:
 - mit Nebenbedingungen ist das bekannte $\vec{c} = (X^T X)^{-1} X^T \vec{y}$ keine Lösung mehr!

Beispiel: Constrained Least Squares Regression


Beispiele von Nebenbedingungen

- Nebenbedingung: Ausgabewert darf nicht negativ werden
 - z.B.: Ausgabe ist nicht-negative physikalische Größe
 - Nachfolgende Algorithmen erfordern nicht-negative Eingaben
- Summe der Koeffizienten soll 1 sein
 - um Skala der Ausgabe zu kontrollieren
 - für Mischungsmodelle
- Ausgabe zwischen 0 und 1
 - Bekannte Grenzen der Ausgabe

Beispiel: Constrained Least Squares Regression

- Gegebene Daten: Beobachtungen $\vec{y}$ bei $\mathbf{X}$
- Annahme lineare Regression: $\mathbf{X}\vec{b} = \vec{y}$
- Ziel: finde $\vec{b}$ mit minimalen quadratischen Fehlern (d.h., least squares)
 - Fehler: $\|\vec{y} - \mathbf{X}\vec{b}\|_2^2$
- **Nebenbedingung:** Koeffizienten $\vec{b}$ mit $b_i > 0$

Beispiel: Constrained Least Squares Regression



Beispiel: Zielfunktion

- Zielfunktion:

- $\|\vec{y} - \mathbf{X}\vec{b}\|_2^2$
- $(\vec{y} - \mathbf{X}\vec{b})^T(\vec{y} - \mathbf{X}\vec{b})$
- $\vec{y}^T\vec{y} - \vec{y}^T\mathbf{X}\vec{b} - (\mathbf{X}\vec{b})^T\vec{y} + (\mathbf{X}\vec{b})^T\mathbf{X}\vec{b}$
- entferne Konstanten ($\vec{y}^T\vec{y}$) und vereinfachen
- $-\vec{y}^T\mathbf{X}\vec{b} - (\mathbf{X}\vec{b})^T\vec{y} + \vec{b}^T\mathbf{X}^T\mathbf{X}\vec{b}$
- $-2\vec{y}^T\mathbf{X}\vec{b} + \vec{b}^T\mathbf{X}^T\mathbf{X}\vec{b}$
- teile durch 2 (ändert Optimum nicht)
- $\frac{1}{2}\vec{b}^T\mathbf{X}^T\mathbf{X}\vec{b} - \vec{y}^T\mathbf{X}\vec{b}$

Beispiel: Constrained Least Squares Regression

$$\begin{array}{ll} \underset{\vec{b}}{\text{minimiere}} & f(\vec{b}) : \frac{1}{2} \vec{b}^T \mathbf{X}^T \mathbf{X} \vec{b} - \vec{y}^T \mathbf{X} \vec{b} \\ \text{mit} & 0 \leq b_i \end{array}$$

- Ist ein QO Problem!

Beispiel: Constrained Least Squares Regression

$$\begin{array}{ll} \underset{\vec{b}}{\text{minimiere}} & f(\vec{b}) : \frac{1}{2} \vec{b}^T \mathbf{Q} \vec{b} - \vec{c}^T \vec{b} \\ \text{mit} & 0 \leq b_i \end{array}$$

$$\text{mit } \mathbf{Q} = \mathbf{X}^T \mathbf{X}$$

$$\text{und } \vec{c} = \mathbf{X}^T \vec{y}$$

Überblick

Eigenschaften von Algorithmen/Methoden

Methode	Global	Gradientenbasiert	Nebenbedingungen	Ziele	Linear	Ansatz	Genauigkeit	Deterministisch	Variablen
Stationäre Punkte / Hesse	✓	✓	ohne	1	✗	analytisch	exakt	✓	$\mathbb{R}^n$
Gradient Descent	✗	✓	ohne	1	✗	numerisch	?	✓	$\mathbb{R}^n$
Simplex	✗	✓	alle	1	✓	numerisch	exakt	✓	$\mathbb{R}^n$ & $\mathbb{Z}^n$
QO	✗	✓	alle	1	Nebenbed.	numerisch	?	✓	$\mathbb{R}^n$

R Anwendung

- Siehe Beispiele in AnwendungOV-04a-CLS.Rmd
- Anpassen des letzten Beispiels mit neuer Nebenbedingung: die Summe der Koeffizienten soll Null ergeben (mit Ausnahme des y-Achsenabschnitts)

Nicht-lineare Optimierung mit Nebenbedingungen

Analytische Lösung, Bedingungen

- Erinnerung, ohne Nebenbedingungen:
 - Notwendig: $\nabla f(\vec{x}) = \vec{0}$
 - Ausreichend: Hessematrix positiv / negativ definit

Analytische Lösung: KKT Bedingungen

- Problem

$$\begin{array}{ll}\underset{\vec{x}}{\text{minimiere}} & f(\vec{x}) \\ \text{mit} & h_k(\vec{x}) = 0, \quad k = 1, \dots, l \\ & g_j(\vec{x}) \leq 0, \quad j = 1, \dots, m\end{array}$$

- $h_k(\vec{x}) = 0$: Gleichungsnebenbedingungen
- $g_j(\vec{x}) \leq 0$: Ungleichungsnebenbedingungen
- Optimalitätsbedingungen: Karush-Kuhn-Tucker (KKT)

Analytische Lösung: KKT Bedingungen

- Wir schreiben alle Ungleichungen in der Form $g_j(\vec{x}) \leq 0$
- Lagrange-Funktion:

$$\mathcal{L}(\vec{x}, a, b) = f(\vec{x}) + \sum_{k=1}^l a_k h_k(\vec{x}) + \sum_{j=1}^m b_j g_j(\vec{x})$$

- a_k : Multiplikatoren zu den Gleichungsnebenbedingungen
- b_j : Multiplikatoren zu den Ungleichungsnebenbedingungen

Analytische Lösung: KKT Bedingungen

Die KKT-Bedingungen bestehen aus vier Blöcken:

1. Stationarität

$$\nabla_{\vec{x}} \mathcal{L}(\vec{x}, a, b) = \nabla_{\vec{x}} f(\vec{x}) + \sum_{k=1}^l a_k \nabla_{\vec{x}} h_k(\vec{x}) + \sum_{j=1}^m b_j \nabla_{\vec{x}} g_j(\vec{x}) = \vec{0}$$

2. Primal Feasibility

$$h_k(\vec{x}) = 0, \quad g_j(\vec{x}) \leq 0$$

3. Dual Feasibility

$$b_j \geq 0$$

4. Komplementarität

$$b_j g_j(\vec{x}) = 0$$

Analytische Lösung: KKT Bedingungen

- Interpretation der Komplementarität:
 - **aktiv**: $g_j(\vec{x}) = 0$ und dann kann $b_j > 0$ sein
 - **inaktiv**: $g_j(\vec{x}) < 0$ und dann muss $b_j = 0$ gelten
- Ohne Ungleichungsnebenbedingungen reduzieren sich die KKT-Bedingungen auf die klassische Lagrange-Methode.
- Für Maximierungsprobleme kann man entweder
 - KKT für ein Maximum umformulieren (ändert ein paar Details) oder
 - äquivalent $-f(\vec{x})$ minimieren

Analytische Lösung: KKT Bedingungen

Unterscheidung ob Minimum / Maximum / Sattel gefunden?

- KKT-Bedingungen sind im Allgemeinen **notwendig**, aber nicht immer **hinreichend**.
- Wie bei Optimierung ohne Nebenbedingungen: Prüfe Hessematrix (Bedingung zweiter Ordnung)
- Dazu: Verwenden die Hessematrix der **Lagrange-Funktion bezüglich $\vec{x}$** (**nicht** Ableitungen nach den Multiplikatoren)
- Wenn Hessematrix positiv definit (für Punkt der KKT Bedingung erfüllt):
 - Lokales Minimum
- Wenn nicht: Problem! Unklar!
 - Richtungen in denen es weiter Abwärts geht (bei Sattel) könnten unzulässig sein, also der Punkt trotzdem ein Lokales Minimum

KKT: Dosen-Beispiel

minimiere
 d, h


$$f(d, h) : C\pi dh$$

mit

$$h_1(d, h) : \pi d^2 h / 4 - 500 = 0$$

$$g_1(d, h) : 2d - h \leq 0$$

$$6 \leq d \leq 9 ; 12 \leq h \leq 18$$



KKT: Dosen-Beispiel - Analytische Lösung

Lagrange-Funktion:

$$L(d, h, a_1, b_1) = C\pi dh + a_1 (\pi d^2 h / 4 - 500) + b_1 (2d - h)$$

KKT-Bedingungen:

$$\partial L / \partial d = C\pi h + a_1 \pi d h / 2 + 2b_1 = 0$$


$$\partial L / \partial h = C\pi d + a_1 \pi d^2 / 4 - b_1 = 0$$

$$\pi d^2 h / 4 - 500 = 0$$

$$2d - h \leq 0$$

$$b_1 \geq 0$$

$$b_1 (2d - h) = 0$$



Zur Vereinfachung nehmen wir die Grenznebenbedingungen für d und h nicht in die KKT-Bedingungen auf. Wir prüfen die gefundene Lösung anschließend separat auf Zulässigkeit.

KKT: Dosen-Beispiel - Analytische Lösung

Fall 1: $b_1 = 0$

- Dann folgt aus der Stationarität:

$$C\pi h + a_1\pi dh/2 = 0$$

$$C\pi d + a_1\pi d^2/4 = 0$$

- Da im zulässigen Bereich $d > 0$ und $h > 0$ gilt:

$$C + a_1 d/2 = 0$$

$$C + a_1 d/4 = 0$$

- Subtraktion der beiden Gleichungen liefert:

$$a_1 d \left(\frac{1}{2} - \frac{1}{4} \right) = 0$$

- Wegen $d > 0$ müsste also $a_1 = 0$ gelten.
- Dann folgt aber $C = 0$, Widerspruch zu $C > 0$.
- Also: **Fall $b_1 = 0$ ist unmöglich.**

KKT: Dosen-Beispiel - Analytische Lösung

Fall 2: $b_1 > 0$

Dann folgt aus der Komplementaritätsbedingung sofort:

$$2d - h = 0 \quad \Rightarrow \quad h = 2d$$

Zusammen mit der Volumenbedingung

$$\pi d^2 h / 4 = 500$$

erhält man:

$$\frac{\pi d^2 (2d)}{4} = 500$$

$$\frac{\pi d^3}{2} = 500$$

$$d^3 = \frac{1000}{\pi}$$

KKT: Dosen-Beispiel - Analytische Lösung

Damit:

$$d = \left(\frac{1000}{\pi} \right)^{\frac{1}{3}} \approx 6.827841$$

$$h = 2d = \left(\frac{8000}{\pi} \right)^{\frac{1}{3}} \approx 13.65568$$

KKT: Dosen-Beispiel - Analytische Lösung

Kontrolle der Multiplikatoren:

Einsetzen von d, h in Stationaritätsbedingungen.

Ergibt näherungsweise:

$$a_1 \approx -0.003905578$$

$$b_1 \approx 0.07150098$$

Dabei ist insbesondere $b_1 \geq 0$ erfüllt.

KKT: Dosen-Beispiel - Analytische Lösung

Gefundene Lösung:

$$d \approx 6.827841$$

$$h \approx 13.65568$$

Nachträglicher Zulässigkeitscheck der weggelassenen Grenznebenbedingungen:

$$6 \leq d \leq 9, \quad 12 \leq h \leq 18$$

Die Lösung ist also auch für das ursprüngliche Problem zulässig.

Mit $C = 0.01$ Euro / cm² ergeben sich Kosten von

$$f(d, h) = C\pi dh \approx 2.93 \text{ Euro}$$

KKT: Dosen-Beispiel - Analytische Lösung

Ist das auch wirklich ein Minimum?

Hessematrix der Lagrange-Funktion: indefinit! Hier also **nicht** der passende Test. Entscheidend wäre die Krümmung auf dem zulässigen Richtungsraum.

Hier sind am gefundenen Punkt aktiv:

- die Gleichungsnebenbedingung $\pi d^2 h / 4 - 500 = 0$
- die Ungleichungsnebenbedingung $2d - h \leq 0$, da $h = 2d$

Damit ist der Punkt durch die aktiven Nebenbedingungen bereits eindeutig festgelegt. Aus den KKT-Bedingungen erhalten wir also genau einen zulässigen Kandidaten:

$$(d, h) = \left(\left(\frac{1000}{\pi} \right)^{1/3}, \left(\frac{8000}{\pi} \right)^{1/3} \right)$$

Dass dieser Punkt optimal ist, können wir uns auch einfach grafisch anschauen.

Dosen-Beispiel - Grafische Lösung

minimiere
 d, h


$$f(d, h) : C\pi dh$$

mit


$$h_1(d, h) : \pi d^2 h / 4 - 500 = 0$$

$$g_1(d, h) : 2d - h \leq 0$$

$$6 \leq d \leq 9 ; 12 \leq h \leq 18$$



Dosen-Beispiel - Grafische Lösung



Überblick

Eigenschaften von Algorithmen/Methoden

Methode	Global	Gradientenbasiert	Nebenbedingungen	Ziele	Linear	Ansatz	Genauigkeit	Deterministisch	Variablen
Stationäre Punkte / Hesse	✓	✓	ohne	1	✗	analytisch	exakt	✓	$\mathbb{R}^n$
Gradient Descent	✗	✓	ohne	1	✗	numerisch	?	✓	$\mathbb{R}^n$
Simplex	✗	✓	alle	1	✓	numerisch	exakt	✓	$\mathbb{R}^n$ & $\mathbb{Z}^n$
QO	✗	✓	alle	1	Nebenbed.	numerisch	?	✓	$\mathbb{R}^n$
KKT	✓	✓	alle	1	✗	analytisch	exakt	✓	$\mathbb{R}^n$

Algorithmus: Sequentielle Quadratische Optimierung

Sequentielle Quadratische Optimierung

- Solver für Nichtlineare Optimierung (NLO)
- Intuitive Idee:
 - Quadratische Approximation der NL Zielfunktion
 - Lineare Approximation der NL Nebenbedingungen
 - Löse mit QO Solver

Nichtlineares Problem mit Nebenbedingungen

$$\begin{array}{ll} \underset{\vec{x}}{\text{minimiere}} & f(\vec{x}) \\ \text{mit} & h_k(\vec{x}) = 0 \\ & g_j(\vec{x}) \leq 0 \end{array}$$

Nichtlineares Problem mit Nebenbedingungen

mit Lagrangian:

$$\begin{array}{ll} \text{minimiere} & F(\vec{x}) : \mathcal{L}(\vec{x}, a, b) = f(\vec{x}) + \sum_{k=1}^l a_k h_k(\vec{x}) + \sum_{j=1}^m b_j g_j(\vec{x}) \\ & \vec{x} \\ \text{mit} & h_k(\vec{x}) = 0 \\ & g_j(\vec{x}) \leq 0 \end{array}$$

Quadratische Approximation

$$\begin{array}{ll} \underset{\vec{d}}{\text{minimiere}} & \tilde{f}_i(\vec{d}) = f(\vec{x}_i) + \nabla f(\vec{x}_i)^T \vec{d} + \frac{1}{2} \vec{d}^T \mathbf{H} \vec{d} \\ \text{mit} & \tilde{h}_{ki}(\vec{d}) = h_k(\vec{x}_i) + \nabla h_k(\vec{x}_i)^T \vec{d} \\ & \tilde{g}_{ji}(\vec{d}) = g_j(\vec{x}_i) + \nabla g_j(\vec{x}_i)^T \vec{d} \end{array}$$

- i : aktuelle Iteration des SQO Algorithmus
- $\vec{x}_i$: aktueller Lösungskandidat
- $\vec{d} = \vec{x}^* - \vec{x}_i$
- $\mathbf{H}$: Hessematrix der Lagrange Funktion $\mathcal{L}(\vec{x}, a, b)$.
 - Anmerkung: $\mathbf{H}$ wird meist auch nur angenähert (BFGS)
- Optimum $\vec{d}$ ist die Suchrichtung für diese Iteration

Sequentielle Quadratische Optimierung

1. Setze Startlösung $\vec{x}_{i=0}$
 2. Minimiere quadratische Approximation, finde Suchrichtung $\vec{d}$ (d.h., Lösen des Sub-problems)
 3. Bestimme Schrittgröße $c > 0$ mittels Liniensuche (1D Suche)
 4. $\vec{x}_{i+1} = \vec{x}_i + c\vec{d}$ bestimme Lösungskandidat für nächste Iteration
 5. Wenn konvergiert: Beende Algorithmus
 6. Sonst: setze $i = i + 1$ und gehe zu 2.
- Eigenschaften von SQO: behandelt Nebenbedingungen, lokal, gradientenbasiert, deterministisch (wenn $\vec{x}_{i=0}$ festliegt), einziel, reell, nichtlinear.

Überblick

Eigenschaften von Algorithmen/Methoden

Methode	Global	Gradientenbasiert	Nebenbedingungen	Ziele	Linear	Ansatz	Genauigkeit	Deterministisch	Variablen
Stationäre Punkte / Hesse	✓	✓	ohne	1	✗	analytisch	exakt	✓	$\mathbb{R}^n$
Gradient Descent	✗	✓	ohne	1	✗	numerisch	?	✓	$\mathbb{R}^n$
Simplex	✗	✓	alle	1	✓	numerisch	exakt	✓	$\mathbb{R}^n$ & $\mathbb{Z}^n$
QO	✗	✓	alle	1	Nebenbed.	numerisch	?	✓	$\mathbb{R}^n$
KKT	✓	✓	alle	1		analytisch	exakt	✓	$\mathbb{R}^n$
SQO	✗	✓	alle	1		numerisch	?	✓	$\mathbb{R}^n$

R Anwendung

- Siehe Code-Beispiele in AnwendungOV-04b-SQO.Rmd
- Aufgabe: Löse Dosen-Beispiel mit SQO