

Optimierungsverfahren

Teil 07 - Mehrzieloptimierung

Martin Zaefferer

MO: Grundlagen

Literatur / Quellen

- Eckart Zitzler. 1999. Evolutionary Algorithms for Multiobjective Optimization: Methods and Applications. Ph.D. Dissertation. ETH Zurich, Switzerland.
- Andreia P. Guerreiro, Carlos M. Fonseca, and Luís Paquete. 2021. The Hypervolume Indicator: Computational Problems and Algorithms. ACM Comput. Surv. 54, 6, Article 119 (July 2022), 42 pages. <https://doi.org/10.1145/3453474>
- N. Srinivas and Kalyanmoy Deb. 1994. Multiobjective optimization using nondominated sorting in genetic algorithms. Evol. Comput. 2, 3 (Fall 1994), 221–248. <https://doi.org/10.1162/evco.1994.2.3.221>
- K. Deb, A. Pratap, S. Agarwal and T. Meyarivan, “A fast and elitist multiobjective genetic algorithm: NSGA-II,” in IEEE Transactions on Evolutionary Computation, vol. 6, no. 2, pp. 182-197, April 2002, doi: 10.1109/4235.996017.
- Beume, Nicola, Naujoks, Boris and Rudolph, Günter. “SMS-EMOA – Effektive evolutionäre Mehrzieloptimierung (SMS-EMOA – Effective Evolutionary Multiobjective Optimization)” , vol. 56, no. 7, 2008, pp. 357-364.

Motivation

- Die meisten Optimierungsprobleme berücksichtigen **mehrere** Ziele, z.B.:
 - Produktdesign: minimale Kosten, maximale Qualität
 - Tragflächenoptimierung: minimaler Widerstand, maximaler Auftrieb
 - Automotor: minimale Emissionen, maximaler Wirkungsgrad, minimale Kosten
- Manchmal lassen sich diese Ziele intuitiv zusammenfassen (z. B. minimale Kosten und maximaler Umsatz → maximaler Ertrag)
- Oft sind die Ziele widersprüchlich, und die Aggregation ist nicht eindeutig / trivial

Mehrziel Optimierung (MO)

- Einziel Problem

$$\begin{array}{ll} \underset{\vec{x}}{\text{minimiere}} & y = f(\vec{x}) \\ & \text{mit } y \in \mathbb{R} \end{array}$$

- Mehrziel Problem mit m Zielen


$$\begin{array}{ll} \underset{\vec{x}}{\text{minimiere}} & y_1 = f_1(\vec{x}), y_2 = f_2(\vec{x}), \dots, y_m = f_m(\vec{x}) \\ & \text{mit } y_i \in \mathbb{R}, \text{ und } i = 1, \dots, m. \end{array}$$

- Mehrziel Problem (Vektornotation)

$$\begin{array}{ll} \underset{\vec{x}}{\text{minimiere}} & \vec{y} = f(\vec{x}) \\ & \text{mit } \vec{y} \in \mathbb{R}^m \end{array}$$


Beispiel: 2 Ziele, 1 Variable

- minimiere $f_1(x) = (x - 1)^2$
 $f_2(x) = (x + 1)^2$
- Frage: Lösung für dieses Problem?




Beispiel: 2 Ziele, 1 Variable

- Optimal in Bezug auf f_1 nur: $x_1^* = 1$
- Optimal in Bezug auf f_2 nur: $x_2^* = -1$




Beispiel: 2 Ziele, 1 Variable

- Optimal in Bezug auf f_1 nur: $x_1^* = 1$
- Optimal in Bezug auf f_2 nur: $x_2^* = -1$
- Auch optimal: $x_3^* = 0$,
weil: $f_2(x_3^*) < f_2(x_1^*)$
und: $f_1(x_3^*) < f_1(x_2^*)$




Beispiel: 2 Ziele, 1 Variable

- Ein Punkt $x^* \in \mathbb{R}$ ist optimal, wenn es keinen anderen Punkt $x \in \mathbb{R}$ gibt, der in Bezug auf **alle** Zielfunktionen gleich oder besser ist und in mindestens einer Funktion besser ist.
 - Auch genannt: Pareto-optimal
- Daraus folgt: die Lösung dieses Problems (und der meisten Mehrzielprobleme) ist eine **Menge** von Vektoren, und nicht ein einzelner Vektor im Suchraum.
 - Auch genannt: Pareto-Menge
- Mit anderen Worten: Lösungen sind alle möglichen Kompromisse zwischen den beiden Zielen
- Hier: Pareto-Menge ist $-1 \leq x^* \leq 1$



Beispiel: 2 Ziele, 1 Variable

Darstellung der Pareto-Menge im Zielfunktionsraum (Auch: **Pareto-Front**):




Beispiel: 2 Ziele, 1 Variable

- Frage: Können Sie sich ein ähnliches 2-Ziel-Problem vorstellen, bei dem die Lösung nur ein einziger Wert (anstatt einer Menge) ist?


Beispiel: 2 Ziele, 1 Variable

- $f_1(x) = 4x^2$, $f_2(x) = x^2$



Beispiel: 2 Ziele, 1 Variable

Darstellung der Pareto-Menge im Zielfunktionsraum (Auch: **Pareto-Front**):




Beispiel: 2 Ziele, 2 Variablen

- Dasselbe für zwei Variablen:

$$f_1(\vec{x}) = (x_1 - 1)^2 + (x_2 - 1)^2,$$

$$f_2(\vec{x}) = (x_1 + 1)^2 + (x_2 + 1)^2$$

- Optimum für alle $\vec{x}^*$ mit $x_1^* = x_2^*$ und $-1 \leq x_1^* \leq 1$
- Dies sind wiederum alle Punkte, für die kein anderer Punkt in allen Zielen besser ist



Beispiel: 3 Ziele, 2 Variablen


- Das Gleiche für 2 Variablen und 3 Ziele:

$$f_1(\vec{x}) = (x_1 - 1)^2 + (x_2 - 1)^2,$$

$$f_2(\vec{x}) = (x_1 + 1)^2 + (x_2 + 1)^2,$$

$$f_3(\vec{x}) = (x_1 - 1)^2 + (x_2 + 1)^2$$

- Frage: Wo liegt die Pareto-Menge?



Beispiel: 3 Ziele, 2 Variablen


- Das Gleiche für 2 Variablen und 3 Ziele:

$$f_1(\vec{x}) = (x_1 - 1)^2 + (x_2 - 1)^2,$$



$$f_2(\vec{x}) = (x_1 + 1)^2 + (x_2 + 1)^2,$$

$$f_3(\vec{x}) = (x_1 - 1)^2 + (x_2 + 1)^2$$



- Pareto-Menge: schattierte Region





Beispiele: Plots im Zielfunktionsraum



Beispiele: Plots im Zielfunktionsraum





Andere Zielfunktionsformen



$$f_1(\vec{x}) = |x_1 - 1| + |x_2 - 1|, \quad f_2(\vec{x}) = |x_1 + 1| + |x_2 + 1|$$


Andere Zielfunktionsformen



$$f_1(x) = |x - 1|^{1/2}, f_2(x) = |x + 1|^{1/2}$$

Definition: Pareto-Dominanz / -Optimalität

- **Pareto-Dominanz:** $\vec{x}'$ dominiert $\vec{x}''$, wenn
 - $f_i(\vec{x}') \leq f_i(\vec{x}'')$ für alle $i \in \{1, \dots, m\}$ und
 - $f_i(\vec{x}') < f_i(\vec{x}'')$ für mindestens ein $i \in \{1, \dots, m\}$
- **Pareto-optimal:** $\vec{x}$ ist Pareto-optimal, wenn von keinem anderen Punkt dominiert (auch: 'non-dominated')
- **Pareto-Menge:** Menge aller Pareto-optimaler (non-dominated) Lösungskandidaten
- **Pareto-Front:** Repräsentation der Pareto-Menge im Zielraum



Roter Punkt dominiert graue Punkte (innerhalb des durch gestrichelte Linien gekennzeichneten Bereichs)

MO: Numerische Suche

MO: Numerische Suche

- Numerische Suche: Annäherung an die vollständige Pareto-Menge
- Wie würden Sie nach Pareto-optimalen Lösungen suchen?

MO: Numerische Suche


- Numerische Suche: Annäherung an die vollständige Pareto-Menge
- Wie würden Sie nach Pareto-optimalen Lösungen suchen?
- Einfacher Ansatz: gewichtete Summen von Zielen
 - Definiere unterschiedliche Gewichte für beide Ziele
 - Für jede Kombination von Gewichten: eine Einzelzieloptimierung durchführen
 - Kombination aller Einzelziel-Optima ist die approximierte Paretofront

Anwendung: MO mit gewichteter Summe

- Siehe AnwendungOV-07a-Mehrziel.Rmd

Numerische Suche mit NSGA-II

EA



NSGA-II

- Non-dominated Sorting Genetic Algorithm (NSGA)
- EA für MO
- Warum eignen sich EA für MO?

NSGA-II

- Non-dominated Sorting Genetic Algorithm (NSGA)
- EA für MO
- Warum eignen sich EA für MO?
 - MO: Lösungen sind Mengen (Pareto-Menge)
 - EA: Arbeiten meist mit Mengen (Populationen)

Siehe:


(Srinivas and Deb, 1994)

(Deb et al., 2002)


Non-Dominated Sorting Rank (NDSR)

- Zentrales Element vieler MO-EAs, inklusive NSGA-II
- Gegeben: Menge von Punkten (im Zielfunktionsraum), Start: Rang $i = 1$
 1. Alle nicht-dominierten Punkte erhalten den Rang i
 2. Die Punkte mit Rang werden aus der berücksichtigten Punktmenge entfernt
 3. $i=i+1$
- Punkte 1. bis 3. solange wiederholen, bis alle Punkte einen Rang erhalten haben.


Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel




Non-Dominated Sorting Rank, Beispiel



Non-Dominated Sorting Rank, Beispiel



Non-Dominated Sorting Rank, Beispiel




NSGA-II

- Einfacher GA basierend auf non-dominated sorting:
 - Gleiches Verfahren wie Einzel-EAs
 - Wichtiger Unterschied: Überlebensauswahl nach NDSR
- Problem: Gleichstand von Lösungen, bzw. wie man zwischen Lösungen mit gleichem Rang auswählen kann
- In NSGA-II: Crowding Distance entscheidet bei Gleichstand ('Abstand' zwischen Lösungen im Zielraum)
- Führt zu besserer Verteilung von Lösungen (Diversität), d.h. bessere Annäherung an die wahre Pareto-Front

Crowding distance

- Nur für Punkte auf derselben Front berechnet (d. h., sie dominieren sich nicht gegenseitig).
- Basierend auf den umschließenden Nachbarn
- Summe der Abstände zwischen den umschließenden Nachbarn in jedem Ziel
- Skalierung der Abstände: Teilen durch den größten beobachteten Abstand zwischen zwei beliebigen Punkten
- Extrempunkte: werden *immer* gewählt, bzw. erhalten maximale Crowding Distance



Punkte: Lösungen auf der Paretofront (non-dominated),
Kreise: dominierte Lösungen, gestrichelte Linie: Abstände
in jeder Zieldimension


Anmerkung: Extrempunkte

- Mit Bezug zu Crowding Distance: Extrempunkte einer Pareto-Front sind solche, für die in mindestens einem Ziel (isoliert betrachtet) keine größeren ODER kleineren Werte in anderen Punkten vorliegen
 - Unabhängig von Minimierung oder Maximierung!

Beispiel: NSGA ohne Crowding Distance

$$\begin{aligned} \underset{x}{\text{minimiere}} \quad & f_1(x) = (x - 1)^2 \\ & f_2(x) = (x + 1)^2 \end{aligned}$$


Linie: wahre Pareto-Front, Kreise: Annäherung mit NSGA2



Beispiel: NSGA mit Crowding Distance

$$\begin{aligned} \underset{x}{\text{minimiere}} \quad & f_1(x) = (x - 1)^2 \\ & f_2(x) = (x + 1)^2 \end{aligned}$$

Linie: wahre Pareto-Front, Kreise: Annäherung mit NSGA2



NSGA-II: Algorithmus

1. Initiale Population erstellen
2. Eltern auswählen (NDSR & CD)
3. Rekombinieren, um Nachkommen zu erzeugen
4. Nachkommen mutieren
5. Auswahl der Überlebenden für die nächste Generation (NDSR & CD)
6. Stopp wenn gewünscht, sonst gehe zu Schritt 2.

Anwendung: NSGA-II

- siehe AnwendungOV-07b-Mehrziel.Rmd


Hypervolumen

Alternative Tie-Breaks: Hypervolumen

- Es gibt ausser Crowding distance noch weitere Indikatoren für Tie-breaks:
 - R1-, R2- und R3-Indikator
 - ϵ -Indikator
 - **Hypervolumen**, bzw. **Hypervolumenbeitrag** (auch: S-Metric)


Hypervolumen der Pareto front

- Hypervolumen (hier: Fläche), das durch alle Punkte enthält, die durch Pareto-front 'dominiert' werden, bis zu einem Referenzpunkt




Hypervolumenbeitrag

- Hypervolumen, das durch jeden Pareto-optimalen Punkt zum gesamten Hypervolumen der Front beigetragen wird.
 - Die Randpunkte (Extrempunkte) erhalten häufig künstlich den größten Beitrag, bzw. einen Beitrag von ∞
- Frage: Welche der 4 Punkte in der Grafik haben den größten Hypervolumenbeitrag



Hypervolumenbeitrag

- Volumen, das durch jeden pareto-optimalen Punkt zum gesamten Hypervolumen der Front beigetragen wird
 - Die Randpunkte (Extrempunkte) erhalten häufig künstlich den größten Beitrag, bzw. einen Beitrag von ∞
- Frage: Welche der 4 Punkte in der Grafik haben den größten Hypervolumenbeitrag



Hypervolumen

- Vorteile
 - Sehr gutes Maß für die Pareto-optimalität einzelner Punkt – Pareto-Compliance
 - Kann auch Mengen (Fronten) Vergleichen, statt nur einzelne Punkte
 - Skalenunabhängig (erfordert keine einheitliche Skalierung der Ziel-Achsen)
- Nachteile:
 - Referenzpunkt benötigt (Parameter, Worst-case Abschätzung, ...)
 - Rechenzeit: wenn große Zahl von Zielfunktionen → relativ großer Rechenaufwand

SMS-EMOA: Algorithmus

1. Initiale Population erstellen
2. Eltern auswählen (NDSR & HVB)
3. Rekombinieren, um Nachkommen zu erzeugen
4. Nachkommen mutieren
5. Auswahl der Überlebenden für die nächste Generation (NDSR & HVB)
6. Stopp wenn gewünscht, sonst gehe zu Schritt 2.

Siehe auch:
(Beume et al., 2008)

Überblick

Eigenschaften von Algorithmen/Methoden

	Methode	Global	Gradientenbasiert	Nebenbedingungen	Ziele	Linear	Ansatz	Genauigkeit	Deterministisch	Variablen
1	Stationäre Punkte / Hesse	✓	✓	ohne	1	✗	analytisch	exakt	✓	$\mathbb{R}^n$
2	Gradient Descent	✗	✓	ohne	1	✗	numerisch	?	✓	$\mathbb{R}^n$
3	Simplex	✗	✓	alle	1	✓	numerisch	exakt	✓	$\mathbb{R}^n$ & $\mathbb{Z}^n$
4	QO	✗	✓	alle	1	Nebenbed.	numerisch	?	✓	$\mathbb{R}^n$
5	KKT	✓	✓	alle	1		analytisch	exakt	✓	$\mathbb{R}^n$
6	SQO	✗	✓	alle	1		numerisch	?	✓	$\mathbb{R}^n$
7	Nelder-Mead	✗	✗	ohne	1		numerisch	approx.	✓	$\mathbb{R}^n$
8	DIRECT	✓	✗	Grenzen	1	✗	numerisch	approx.	✓	$\mathbb{R}^n$
9	Evolutionäre Algorithmen	✓ (?)	✗ (?)	/	/	✗	numerisch	approx.	✗	/
10	(1+1)-ES	✗	✗	ohne	1	✗	numerisch	approx.	✗	$\mathbb{R}^n$
11	CMA-ES	✓ (?)	✗	ohne	1	✗	numerisch	approx.	✗	$\mathbb{R}^n$
14	SMBO	✓ (?)	✗ (?)	/	/	✗	numerisch	approx.	/	/
12	NSGA-II	✓ (?)	✗	ohne	>1	✗	numerisch	approx.	✗	/
13	SMS-EMOA	✓ (?)	✗	ohne	>1	✗	numerisch	approx.	✗	/

Anwendung: SMS-EMOA

- siehe AnwendungOV-07c-Mehrziel.Rmd